UET
ĐẠI HỌC CÔNG NGHỆ, ĐHQGHN
VNU-University of Engineering and Technology

Since 1906
VNU
ĐẠI HỌC QUỐC GIA HÀ NỘI
Vietnam National University, Hanoi

# PE-GH

## Tìm kiếm câu hỏi kỹ thuật bằng truy xuất lai có chọn lọc

Pre-Encoding Gated Hybrid Retrieval

Sinh viên thực hiện: Đầu Hồng Quang MSV: 23020135
Trần Quang Thành MSV: 23020155
Hoàng Quốc Bảo MSV: 23020012

# Nội dung


01 **Bài toán và động lực**

02 **Ý tưởng PE-GH**

03 **Thiết kế hệ thống**

04 **Dữ liệu và cách đánh giá**

# Bài toán truy xuất câu hỏi kỹ thuật

## Câu hỏi minh họa

“How do I change file permissions in Linux?”

## Người dùng cần gì?

Tìm những câu hỏi đã có về cùng một vấn đề, dù cách diễn đạt khác nhau.

**Đầu ra:** tối đa 100 câu hỏi, xếp theo mức độ phù hợp. Hệ thống không sinh câu trả lời.



# Chất lượng và chi phí truy xuất

## BM25

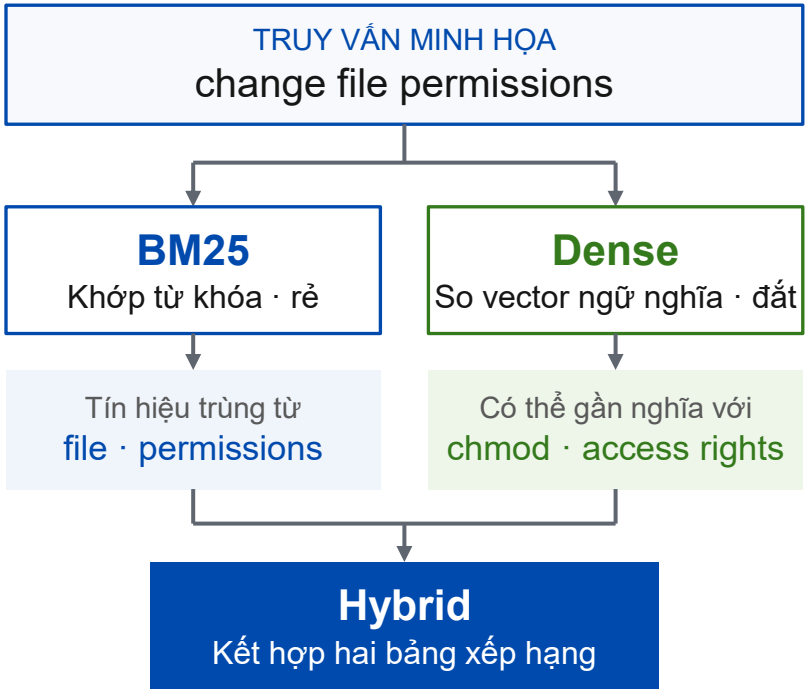
Khớp từ khóa, rất nhanh. Dễ bỏ sót câu hỏi cùng ý nhưng dùng từ khác.

## Dense

Tìm theo ngữ nghĩa. Mỗi truy vấn phải mã hóa bằng transformer rồi tìm vector: bước tốn nhất trên CPU.

## Hybrid

Kết hợp cả hai, thường xếp hạng tốt hơn, nhưng trả toàn bộ chi phí Dense cho mọi truy vấn.



# Khi nào cần Dense?

**BM25 đã đủ**

*“chmod: change file permissions”*

Từ khóa trùng rõ với câu hỏi trong kho, BM25 đã đưa kết quả đúng lên đầu. Chạy thêm Dense chỉ tốn thời gian.

**Cần thêm Dense**

*“How can I display hidden files in Linux?”*

Câu trong kho: “How do I show dotfiles with ls?”. Cùng ý nhưng khác từ (hidden files ↔ dotfiles), BM25 dễ xếp sai.

**Nếu nhận ra trước loại truy vấn, có thể bỏ qua Dense cho các truy vấn dễ.**

# Câu hỏi nghiên cứu

## Có thể biết Dense có cần hay không, trước khi mã hóa truy vấn?

Thông tin có sẵn **trước khi chạy Dense** gồm câu hỏi và danh sách BM25. Liệu chúng đủ để đoán truy vấn nào cần tìm theo ngữ nghĩa?

### Điều kiện để có lợi

Bộ quyết định phải rẻ hơn nhiều so với Dense, đoán đủ đúng, và chất lượng không giảm quá biên cho phép.

# Nghiên cứu liên quan và điểm khác

Định tuyến theo từng truy vấn đã có [1, 2]. PE-GH khác ở **cách huấn luyện gate**, và được so với **quy tắc đơn giản** ở cùng số lần gọi Dense.

## Nghiên cứu đã có

**Arabzadeh và cộng sự, CIKM 2021** [1]
BERT chọn sparse hay dense/hybrid; nhãn: BM25 có tìm thấy kết quả đúng.

**LiteGator, 2025** [2]
SVM tuyến tính trên đặc trưng câu hỏi và điểm BM25; nhãn: Dense có lợi không.

## Gate của PE-GH khác ở

- **Mô hình:** logistic nhẹ trên đặc trưng BM25, không cần BERT như [1].
- **Nhãn:** BM25 có tìm trượt không (như [1]), thay vì Dense có lợi không như [2].
- **Huấn luyện:** nhiều chủ đề, chuẩn hóa theo từng chủ đề; chọn trước tỷ lệ gọi Dense.

[1] N. Arabzadeh, X. Yan, C. L. A. Clarke (2021). *Predicting Efficiency/Effectiveness Trade-offs for Dense vs. Sparse Retrieval Strategy Selection*. CIKM 2021. doi.org/10.1145/3459637.3482159

[2] A.-R. Muhammad, Darmanto, R. L. Atimi (2025). *LiteGator: A Lightweight and Budget-Aware Retriever Routing Framework for Low-Resource Question Answering*. iCAST-ES 2025. doi.org/10.2991/978-94-6463-926-1_77

# PE-GH quyết định điều gì?

Gate xem câu hỏi và danh sách BM25, rồi chọn một trong hai nhánh **trước khi mã hóa truy vấn**.

**A**

## Nhánh rẻ

Trả kết quả BM25. Không chạy transformer, không tìm vector.

GATE

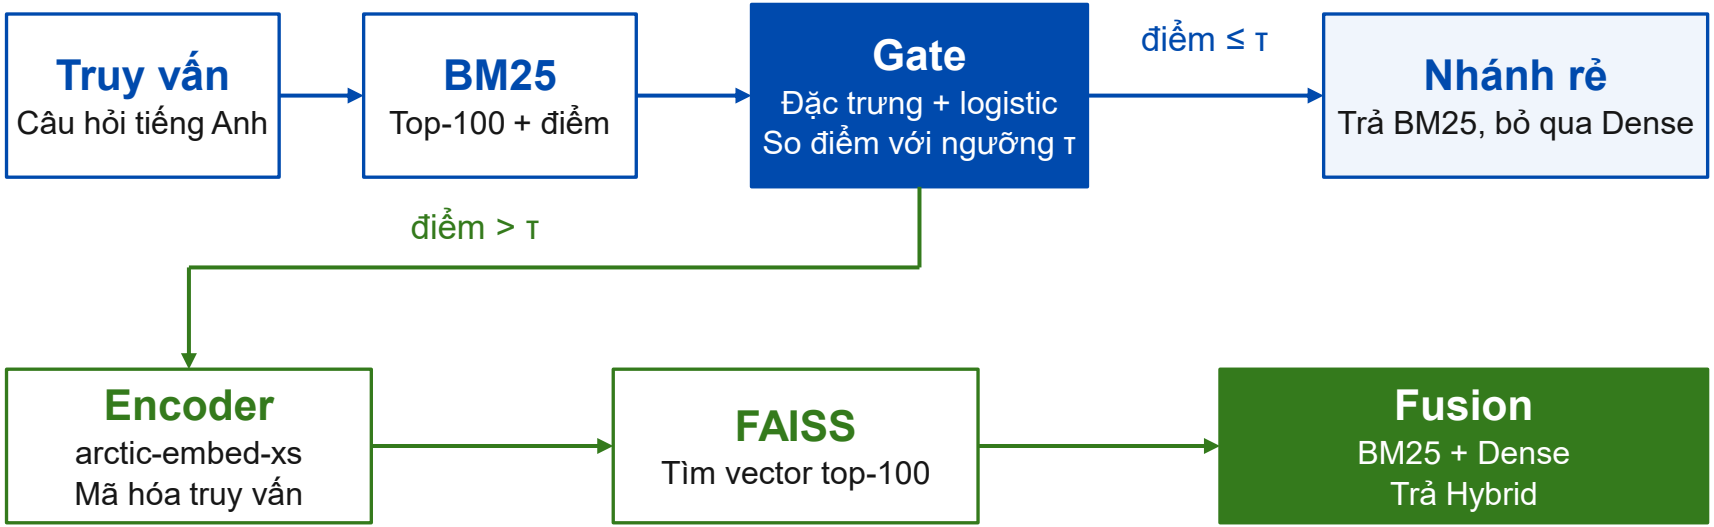
**B**

## Nhánh đầy đủ

Mã hóa truy vấn, tìm vector, kết hợp với kết quả BM25 đã có.

# Một truy vấn trong PE-GH

BM25 chạy một lần. Gate quyết định trước khi mã hóa truy vấn. Vector tài liệu và chỉ mục được chuẩn bị trước.



# Gate học gì?

Gate dự đoán: **BM25 có thất bại** với truy vấn này không?

Nhãn = 1 nếu top-10 của BM25 không có câu hỏi đúng (nDCG@10 của BM25 = 0)

### Vì sao nhãn này?

Gate chỉ thấy câu hỏi và danh sách BM25, nên học được chất lượng của chính BM25. BM25 thất bại thì chỉ Dense cứu được.

### Đầu vào

21 đặc trưng từ câu hỏi, từ vựng và điểm BM25, cộng 7 đặc trưng dự báo chất lượng truy vấn (QPP).

### Mô hình

Hồi quy logistic: một phép nhân vector, chi phí rất nhỏ so với mã hóa truy vấn.

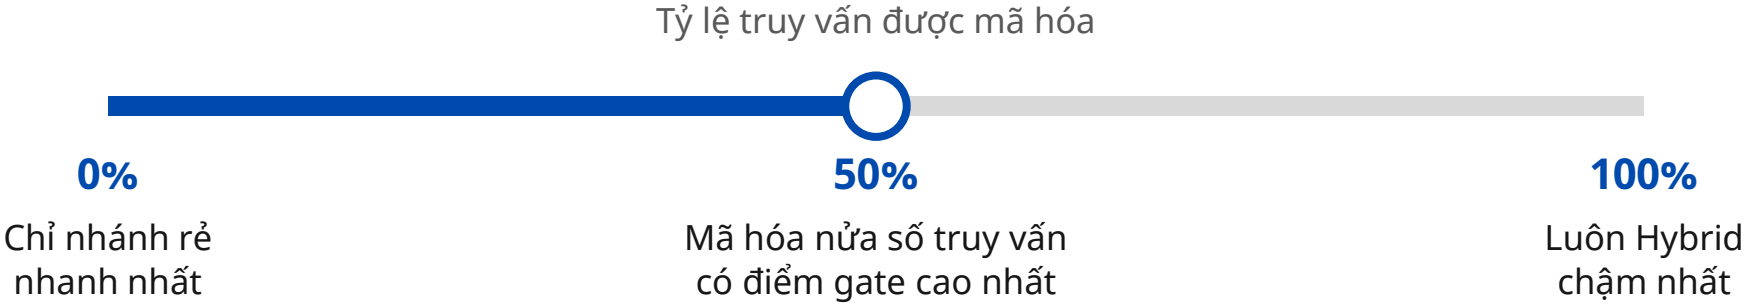
# Ngân sách mã hóa và học nhiều chủ đề

## Ngân sách là ngưỡng điều chỉnh

Chọn trước tỷ lệ truy vấn được mã hóa. Ngưỡng τ = phân vị điểm gate trên các truy vấn đã có, không cần nhãn.

## Học một lần, dùng cho chủ đề mới

Gate học trên nhiều chủ đề. Đặc trưng chuẩn hóa theo thống kê của chính chủ đề đó, nên áp dụng cho chủ đề mới không cần gán nhãn.



# Dữ liệu huấn luyện và đánh giá

**457.199**

bài viết trong 12 chủ đề

**13.145**

truy vấn có nhãn

| Vai trò | Chủ đề | Bài viết | Truy vấn |
|---|---|---|---|
| **Huấn luyện gate** | programmers, unix, android, gis, mathematica, webmasters | 174.303 | 4.842 |
| **Đánh giá** | english, gaming, physics, stats, tex, wordpress | 282.896 | 8.303 |

Gate được học trên 6 chủ đề đầu, đóng băng, rồi mới đánh giá trên 6 chủ đề chưa từng dùng.

Tốc độ thực tế được đo trên programmers và unix.

CQADupStack (BEIR): mỗi chủ đề là một diễn đàn hỏi đáp của Stack Exchange

# Phương pháp so sánh và thước đo

Đối chiếu trên cùng dữ liệu và cùng máy CPU.

| Phương pháp | Cách chọn | Gọi Dense |
|---|---|---|
| **BM25** | Từ khóa | Không |
| **Dense** | Ngữ nghĩa | Luôn |
| **Hybrid** | BM25 + Dense | Luôn |
| **BM25-margin** | Quy tắc chênh điểm BM25 | Theo ngân sách |
| **Ngẫu nhiên** | Chọn ngẫu nhiên | Theo ngân sách |
| **PE-GH** | Gate “BM25 thất bại” | Theo ngân sách |

### Chất lượng

nDCG@10: thứ tự của 10 kết quả đầu.

### Chi phí

Tỷ lệ truy vấn gọi Dense, thời gian CPU.

### Độ trễ

Trung bình, p50 và p95, mỗi lần một truy vấn.

# CẢM ƠN THẦY
# ĐÃ LẮNG NGHE!