ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO ĐỀ TÀI

PE-GH: TRUY XUẤT LAI CÓ CHỌN LỌC TRƯỚC BƯỚC MÃ HÓA TRUY VẤN

Ứng dụng trong tìm kiếm câu hỏi trên CQADupStack

Nhóm thực hiện

Họ và tên	**Mã số sinh viên**
Đầu Hồng Quang	23020135
Trần Quang Thành	23020155
Hoàng Quốc Bảo	23020012

HÀ NỘI, 2026

Tóm tắt

Trong tìm kiếm câu hỏi, truy xuất theo từ khóa và truy xuất ngữ nghĩa có thể bổ sung cho nhau, nhưng việc sử dụng cả hai cho mọi truy vấn làm phát sinh chi phí mã hóa và tìm kiếm vector ngay cả khi kết quả từ khóa đã đáp ứng nhu cầu. Báo cáo nghiên cứu khả năng lựa chọn truy vấn cần truy xuất ngữ nghĩa trước khi thực hiện bước mã hóa truy vấn. Mục tiêu là giảm chi phí xử lý trong một giới hạn suy giảm chất lượng được xác định trước.

Phương pháp PE-GH thực hiện BM25 trước, sau đó sử dụng bộ quyết định nhẹ để lựa chọn giữa nhánh chi phí thấp và nhánh truy xuất lai. Hệ thống cuối PE-GH v2 dựa vào truy vấn và kết quả BM25 để nhận biết những trường hợp có nguy cơ không tìm được tài liệu liên quan trong mười vị trí đầu. Ngân sách truy xuất xác định tỷ lệ truy vấn được ưu tiên sử dụng thêm Dense. Bộ quyết định được học trên sáu miền CQADupStack và giữ cố định khi xác nhận trên sáu miền khác.

Trên 8.303 truy vấn thuộc sáu miền xác nhận, bộ quyết định đạt mức cải thiện trung bình macro nDCG@10 là 0,0042 so với quy tắc BM25-margin ở cùng ngân sách 50%. Với ngân sách vận hành 80%, PE-GH v2 đạt 0,4159 so với 0,4223 của phương pháp luôn chạy Hybrid; chênh lệch nằm trong biên không kém 0,01 đã đăng ký. Trong phép đo riêng trên Programmers và Unix, mức ngân sách 50% cho độ trễ trung bình 14,76 ms so với 24,31 ms của Hybrid cùng phiên. Kết quả cho thấy lựa chọn truy vấn có giá trị trong phạm vi đã đánh giá, nhưng lợi ích của bộ quyết định còn nhỏ, không cải thiện nhất quán độ trễ đuôi và không thay thế ưu thế của việc lựa chọn mô hình ngữ nghĩa phù hợp.

Từ khóa: truy xuất lai, lựa chọn truy vấn, dự báo chất lượng truy xuất, ngân sách mã hóa, CQADupStack.

Abstract

Keyword and semantic retrieval can provide complementary evidence for question search. However, running both methods for every query incurs query encoding and vector search costs even when keyword retrieval already produces useful results. This report studies whether queries can be selected for semantic retrieval before query encoding, with the objective of reducing processing costs under a predefined quality loss tolerance.

PE-GH first runs BM25 and then uses a lightweight gate to choose between a low-cost branch and a hybrid retrieval branch. The final system, PE-GH v2, uses the query and the BM25 results to identify queries at risk of having no relevant document among the top ten results. A retrieval budget controls the proportion of queries assigned to the Dense branch. The gate is trained on six CQADupStack domains and remains fixed during confirmation on six other domains.

On 8,303 confirmation queries, PE-GH v2 improves macro nDCG@10 by 0.0042 over the BM25-margin rule at a matched 50% budget. At the 80% operating budget, it obtains 0.4159 compared with 0.4223 for always-hybrid retrieval, satisfying the preregistered noninferiority margin of 0.01. In a separate online experiment on Programmers and Unix, the 50% operating point achieves a mean latency of 14.76 ms compared with 24.31 ms for the hybrid baseline measured in the same session. These results support selective retrieval within the evaluated setting, while showing a small gate-specific effect, limited improvement in tail latency, and the importance of the underlying encoder.

Keywords: hybrid retrieval, query routing, query performance prediction, encoding budget, CQADupStack.

Mục lục

Chương 1 Giới thiệu đề tài **1**
1.1 Bối cảnh và bài toán tìm kiếm câu hỏi . . . 1
1.2 Vấn đề chất lượng và chi phí truy xuất . . . 1
1.3 Giả thiết và câu hỏi nghiên cứu . . . 2
1.4 Mục tiêu, phạm vi và đóng góp . . . 3
1.5 Bố cục báo cáo . . . 4

Chương 2 Cơ sở lý thuyết và nghiên cứu liên quan **5**
2.1 Các khái niệm cần thiết cho bài toán . . . 5
2.2 Dự báo chất lượng và lựa chọn chiến lược truy xuất . . . 5
2.3 Các nghiên cứu liên quan trực tiếp . . . 6
2.4 Định vị hướng tiếp cận của nhóm . . . 8

Chương 3 Phương pháp PE-GH **9**
3.1 Bài toán và mục tiêu lựa chọn truy vấn . . . 9
3.2 Nguyên lý hoạt động của PE-GH . . . 9
3.3 Thông tin dùng cho quyết định . . . 10
3.4 Cơ sở lựa chọn cách học cho bộ quyết định . . . 11
3.5 Vai trò của ngân sách truy xuất . . . 12
3.6 Quá trình hình thành phương pháp cuối . . . 13

Chương 4 Tổ chức và tiêu chí thực nghiệm **14**
4.1 Dữ liệu và phạm vi đánh giá . . . 14
4.2 Phân chia dữ liệu và quy trình nghiên cứu . . . 15
4.3 Các phương pháp đối chứng . . . 16
4.4 Thước đo và nguyên tắc kiểm định . . . 16
4.5 Điều kiện đo chi phí truy xuất . . . 17

Chương 5 Kết quả và thảo luận **18**
5.1 Chất lượng truy xuất trên các miền xác nhận . . . 18
5.2 Kiểm chứng các giả thuyết nghiên cứu . . . 20
5.3 Quan hệ giữa chất lượng và chi phí . . . 21
5.4 Khả năng lựa chọn truy vấn . . . 24
5.5 Đối chiếu các bộ quyết định liên quan . . . 26
5.6 Các trường hợp chưa đáp ứng kỳ vọng . . . 28
5.7 Giới hạn và ý nghĩa của kết quả . . . 29

Chương 6 Kết luận và hướng phát triển **31**
6.1 Trả lời các câu hỏi nghiên cứu . . . 31
6.2 Đóng góp và mức độ giải quyết . . . 31
6.3 Hướng phát triển . . . 32

Tài liệu tham khảo **33**

Thuật ngữ và chữ viết tắt

Thuật ngữ	Ý nghĩa trong báo cáo
BM25	Phương pháp truy xuất theo mức độ khớp từ khóa.
Dense	Truy xuất sử dụng vector biểu diễn ngữ nghĩa.
Hybrid	Truy xuất kết hợp kết quả từ khóa và ngữ nghĩa.
Gate	Bộ quyết định có sử dụng nhánh Dense cho một truy vấn hay không.
Encoder	Mô hình chuyển văn bản thành vector biểu diễn.
QPP	Dự báo chất lượng truy xuất khi chưa biết nhãn liên quan của truy vấn đang phục vụ.
P^*	Nhánh chi phí thấp, sử dụng kết quả BM25 và thông tin ngữ nghĩa đã chuẩn bị trước.
H^*	Nhánh luôn chạy Hybrid, kết hợp BM25 và Dense.
R^*	Đối chứng sử dụng ngữ nghĩa để đánh giá lại các câu hỏi do BM25 tìm được.
nDCG@10	Thước đo chất lượng xếp hạng tại mười kết quả đầu.
Macro	Trung bình có trọng số bằng nhau cho mỗi miền dữ liệu.
AUC	Chỉ số đánh giá khả năng sắp thứ tự mức rủi ro BM25 không tìm được kết quả liên quan.
CI	Khoảng tin cậy của đại lượng được ước lượng.
RSS	Dung lượng bộ nhớ mà chương trình đang sử dụng trong phép đo.
p95	Phân vị 95% của độ trễ yêu cầu truy xuất.

Trong báo cáo, PE-GH v1 và PE-GH v2 là hai phiên bản hệ thống. Ký hiệu v3 và v4 trong hồ sơ dự án chỉ các vòng thực nghiệm. Hệ thống cuối được trình bày là PE-GH v2, được xác nhận trong vòng v4. Từ “miền” chỉ một chủ đề con của CQADupStack.

Danh mục bảng và hình

Danh mục bảng

Bảng	Nội dung	Trang
2.1	Vai trò các hướng nghiên cứu liên quan	8
3.1	Nhóm thông tin của bộ quyết định	11
3.2	Các bước phát triển PE-GH	13
4.1	Phạm vi dữ liệu và vai trò đánh giá	14
5.1	Chất lượng trên sáu miền xác nhận	18
5.2	Chất lượng và chênh lệch theo miền	19
5.3	Kiểm định K1 đến K4	20
5.4	Chi phí và chất lượng trong phiên đo chính	21
5.5	Chất lượng các bộ quyết định liên quan	26
5.6	Chi phí trong phiên đối chiếu bộ quyết định	27
5.7	Các phương án mô hình ngữ nghĩa	29

Danh mục hình

Hình	Nội dung	Trang
3.1	Nguyên lý lựa chọn trước encoder	10
4.1	Phát triển, đóng băng và xác nhận	15
5.1	Khoảng tin cậy các giả thuyết	21
5.2	Quan hệ chất lượng và độ trễ	22
5.3	Chất lượng theo ngân sách Dense	24
5.4	Lợi ích của bộ quyết định theo miền	25
5.5	Độ trễ trong phiên đối chiếu bộ quyết định	27

Chương 1
Giới thiệu đề tài

1.1 Bối cảnh và bài toán tìm kiếm câu hỏi

Trong các cộng đồng hỏi đáp, người dùng thường gặp một vấn đề đã được thảo luận trước đó nhưng không biết câu hỏi cũ sử dụng cách diễn đạt nào. Một người có thể mô tả hiện tượng bằng ngôn ngữ tự nhiên, trong khi câu hỏi liên quan lại đề cập tên công cụ, thông báo lỗi hoặc khái niệm chuyên môn. Hệ thống tìm kiếm cần đưa những câu hỏi phù hợp lên đầu danh sách để người dùng tận dụng tri thức đã có. Khó khăn không chỉ nằm ở việc tìm các văn bản có chung từ ngữ mà còn ở việc nhận biết những mô tả khác nhau của cùng một nhu cầu.

Trong bối cảnh kỹ thuật, sự khác biệt về diễn đạt thường tồn tại đồng thời với yêu cầu khớp chính xác. Chẳng hạn, một truy vấn hỏi cách "thực thi chương trình theo lịch" có thể liên quan đến tài liệu nói về công cụ lập lịch, dù hai văn bản không dùng cùng cụm từ. Ngược lại, nếu truy vấn chứa một mã lỗi hoặc tùy chọn dòng lệnh cụ thể, việc bỏ qua chi tiết đó có thể làm thay đổi hoàn toàn vấn đề cần giải quyết. Hai tình huống này là ví dụ minh họa cho nhu cầu kết hợp tín hiệu từ khóa và tín hiệu ngữ nghĩa; chúng không phải các trường hợp thực nghiệm được dùng để tính kết quả trong báo cáo.

Đề tài xem xét bài toán truy xuất câu hỏi. Đầu vào của hệ thống là một truy vấn dạng văn bản và một kho câu hỏi đã được lập chỉ mục. Đầu ra là danh sách câu hỏi được sắp xếp theo mức độ liên quan. Nhãn trong bộ dữ liệu cho biết những câu hỏi nào có quan hệ phù hợp với truy vấn để đánh giá danh sách đó. Hệ thống không sinh một câu trả lời mới và không đánh giá khả năng diễn đạt của mô hình ngôn ngữ. Việc xác định phạm vi như vậy giúp tập trung vào quyết định truy xuất và chi phí cần thiết để tạo ra danh sách kết quả.

CQADupStack cung cấp môi trường đánh giá phù hợp với bài toán này nhờ các câu hỏi và quan hệ trùng lặp từ nhiều cộng đồng Stack Exchange [1]. Quá trình nghiên cứu bắt đầu với Programmers và Unix, sau đó mở rộng đến các chủ đề khác. Vì tập xác nhận cuối còn bao gồm English và Gaming, báo cáo sử dụng tên gọi chung là tìm kiếm câu hỏi trên CQADupStack. Những nhận xét rút ra từ một miền kỹ thuật không mặc nhiên áp dụng cho mọi miền của tập dữ liệu.

1.2 Vấn đề chất lượng và chi phí truy xuất

Truy xuất theo từ khóa thường có chi phí thấp và khai thác tốt sự xuất hiện của các thuật ngữ cụ thể. Tuy nhiên, kết quả có thể hạn chế khi truy vấn và câu hỏi liên quan biểu đạt cùng ý bằng những từ khác nhau. Truy xuất Dense sử dụng biểu diễn ngữ nghĩa để bổ

sung một nguồn bằng chứng khác về mức độ liên quan. Khi kết hợp hai nguồn, hệ thống Hybrid có thể cải thiện danh sách kết quả so với chỉ dùng một phương pháp. Các kết quả benchmark như BEIR đồng thời cho thấy cần kiểm chứng khả năng tổng quát hóa và giữ những đối chứng từ khóa mạnh khi đánh giá phương pháp truy xuất [2].

Lợi ích chất lượng của Hybrid đi kèm phần công việc phát sinh cho mỗi truy vấn mới. Vector tài liệu có thể được tính và lưu trước, nhưng truy vấn cần được mã hóa tại thời điểm phục vụ. Sau bước này, hệ thống còn phải tìm kiếm vector và kết hợp kết quả với danh sách BM25. Vì vậy, kể cả khi chỉ mục đã sẵn sàng, luôn chạy Hybrid vẫn phải trả chi phí cho nhánh Dense ở mọi yêu cầu. Báo cáo quan tâm đến chi phí xử lý từng truy vấn trong điều kiện chỉ mục và mô hình đã được tải, thay vì đồng nhất chi phí này với thời gian xây dựng hệ thống ban đầu.

Vấn đề nghiên cứu xuất hiện khi mức độ cần thiết của Dense thay đổi theo truy vấn. Nếu BM25 đã đưa câu hỏi liên quan lên đầu danh sách, việc tiếp tục chạy Dense có thể chỉ đem lại lợi ích nhỏ hoặc không làm thay đổi chất lượng. Ngược lại, nếu BM25 thất bại, bỏ qua Dense có thể làm mất cơ hội tìm được kết quả phù hợp. Một chính sách áp dụng giống nhau cho mọi truy vấn không tận dụng sự khác biệt đó. Nhu cầu đặt ra là phân bổ chi phí Dense cho những truy vấn có khả năng cần đến nó, thay vì chỉ giảm tỷ lệ sử dụng Dense một cách tùy ý.

Việc lựa chọn cũng có chi phí riêng. Bộ quyết định càng phức tạp thì phần tiết kiệm được từ bỏ qua Dense càng có nguy cơ bị triệt tiêu. Một bộ quyết định phải mã hóa truy vấn trước khi lựa chọn còn có thể đã trả phần lớn chi phí mà nó muốn tránh. Do đó, đề tài đặt quyết định sau BM25 nhưng trước encoder. Tại thời điểm này, hệ thống đã có một danh sách từ khóa và những thống kê liên quan, nhưng chưa có biểu diễn ngữ nghĩa của truy vấn mới.

Giảm số lần chạy Dense chưa đủ để khẳng định hệ thống tốt hơn trong sử dụng thực tế. Quyết định sai có thể làm giảm chất lượng, còn phần xử lý bổ sung có thể làm mức giảm thời gian nhỏ hơn tỷ lệ bỏ qua Dense. Độ trễ của các yêu cầu chậm nhất cũng có thể không cải thiện nếu những truy vấn đó vẫn đi qua nhánh đắt. Bài toán vì thế cần được đánh giá đồng thời theo chất lượng, tỷ lệ mã hóa và chi phí đầu cuối, với điều kiện so sánh được kiểm soát.

1.3 Giả thiết và câu hỏi nghiên cứu

Các nghiên cứu về độ khó truy vấn cho thấy hiệu quả truy xuất phụ thuộc quan hệ giữa nhu cầu thông tin và dữ liệu [3]. Giả thiết của đề tài là thông tin từ truy vấn và kết quả BM25 có thể cung cấp tín hiệu về khả năng BM25 đáp ứng nhu cầu tìm kiếm. Ví dụ, khoảng cách điểm giữa các kết quả đầu hoặc mức độ phù hợp của từ ngữ trong truy vấn với kho dữ liệu có thể phản ánh sự chắc chắn của kết quả từ khóa. Nếu những tín hiệu này đủ hữu ích, một mô hình nhẹ có thể giúp ưu tiên sử dụng Dense mà không cần nhìn

vào kết quả Dense trước đó. Đây là giả thiết cần kiểm chứng bằng thực nghiệm, không phải bảo đảm rằng mọi truy vấn khó đối với BM25 đều được Dense giải quyết.

Từ giả thiết đó, báo cáo đặt ra bốn câu hỏi nghiên cứu có quan hệ với nhau. Câu hỏi thứ nhất là liệu bộ quyết định học được có mang lại chất lượng tốt hơn một quy tắc đơn giản và lựa chọn ngẫu nhiên khi các phương pháp được sử dụng cùng số lượt Dense. Câu hỏi này tách giá trị của việc lựa chọn truy vấn khỏi lợi ích chỉ đến từ việc dùng thêm tài nguyên.

Câu hỏi thứ hai là liệu PE-GH có thể giảm số lượt mã hóa trong khi chất lượng vẫn nằm trong biên suy giảm cho phép so với luôn chạy Hybrid. Thay vì yêu cầu hai phương pháp đạt điểm hoàn toàn giống nhau, đề tài xác định trước một mức mất mát tối đa để đánh giá ý nghĩa của việc tiết kiệm chi phí. Biên đánh giá này phải được chốt trước khi xem kết quả xác nhận để tránh điều chỉnh tiêu chí theo số liệu thu được.

Câu hỏi thứ ba là việc giảm số lượt Dense có chuyển thành giảm độ trễ và CPU khi hệ thống phục vụ truy vấn thật hay không. Câu trả lời cần dựa trên phép đo trực tiếp, bởi độ trễ còn phụ thuộc bộ quyết định, nhánh chi phí thấp và chi phí kết hợp kết quả. Báo cáo đồng thời xem xét p95 và bộ nhớ để xác định những khía cạnh chưa được cải thiện.

Câu hỏi thứ tư là hệ thống cuối cải thiện đến đâu so với phiên bản ban đầu và những giới hạn nào còn tồn tại. So sánh này bao gồm thay đổi encoder, nhánh truy xuất và cách học của bộ quyết định, nên phản ánh tác động của cả hệ thống. Để tránh quy kết quá mức, báo cáo phân biệt câu hỏi về nâng cấp toàn hệ thống với câu hỏi về giá trị riêng của bộ quyết định.

1.4 Mục tiêu, phạm vi và đóng góp

Mục tiêu phương pháp của đề tài là xây dựng một chính sách truy xuất lai có chọn lọc, trong đó truy vấn mới chỉ được mã hóa khi bộ quyết định lựa chọn nhánh Dense. Hệ thống cuối PE-GH v2 dự đoán khả năng BM25 không tìm được kết quả liên quan, dựa trên thông tin có sẵn trước khi chạy Dense. Ngân sách truy xuất cho phép điều chỉnh mức sử dụng tài nguyên để quan sát những điểm đánh đổi khác nhau giữa chất lượng và chi phí.

Mục tiêu thực nghiệm là đánh giá chính sách này bằng các phép so sánh đủ mạnh. Ngoài BM25 và luôn chạy Hybrid, đề tài giữ quy tắc BM25-margin, lựa chọn ngẫu nhiên và đối chứng biết trước chất lượng của từng nhánh để xác định mức lợi ích thực sự của việc học. Mô hình được phát triển trên sáu miền, sau đó giữ cố định để xác nhận trên sáu miền khác. Những giả thuyết chính, tiêu chí lựa chọn và biên chất lượng được đăng ký trước giai đoạn xác nhận trong quy trình thực nghiệm của nhóm.

Đóng góp thứ nhất là cách tổ chức một bộ quyết định nhẹ theo thông tin mà hệ thống thực sự quan sát được trước encoder, cùng việc đánh giá giới hạn của lựa chọn đó. Ý tưởng lựa chọn chiến lược truy xuất đã có trong nghiên cứu trước [4]; điểm cần chứng minh

trong đề tài là hiệu quả của cấu hình cụ thể trên bài toán, dữ liệu và điều kiện chi phí đã xác định. Báo cáo không xem việc dùng một bộ quyết định nhẹ hoặc đặt tên phương pháp là bằng chứng về tính mới.

Đóng góp thứ hai là bộ bằng chứng thực nghiệm nối chất lượng với chi phí đo thật. So sánh ở cùng ngân sách cho biết việc lựa chọn có hữu ích hay không, còn phép đo đầu cuối cho biết phần lợi ích đó có ý nghĩa vận hành đến đâu. Khoảng tin cậy, kết quả từng miền và các trường hợp không thuận lợi được giữ trong diễn giải. Đóng góp này giúp xác định điều kiện sử dụng hợp lý của phương pháp thay vì chỉ công bố một tỷ lệ tăng tốc tổng hợp.

Phạm vi kết luận được giới hạn ở CQADupStack, mô hình truy xuất ngữ nghĩa đã chọn và môi trường CPU đã đo. Đánh giá chất lượng xác nhận sử dụng sáu miền; đo khi phục vụ truy vấn sử dụng Programmers và Unix với bộ quyết định được huấn luyện không có miền đang đo. Vì vậy, báo cáo không suy rộng số đo thời gian sang mọi chủ đề, phần cứng hoặc tải đồng thời. Kết luận chỉ áp dụng cho phiên bản đã được đánh giá, không tự động áp dụng cho những thay đổi được thực hiện sau đó.

1.5 Bố cục báo cáo

Chương 2 giới thiệu ngắn những khái niệm cần thiết và phân tích các hướng nghiên cứu gần. Chương 3 trình bày nguyên lý PE-GH và cơ sở lựa chọn phương pháp. Chương 4 mô tả dữ liệu, đối chứng và quy trình kiểm chứng. Chương 5 phân tích bằng chứng về chất lượng, chi phí và giới hạn. Cuối cùng, Chương 6 trả lời các câu hỏi nghiên cứu và xác định hướng phát triển phù hợp với những gì đã được chứng minh.

Chương 2

Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Các khái niệm cần thiết cho bài toán

Trong báo cáo, truy xuất theo từ khóa được đại diện bởi BM25 [5]. Phương pháp này sử dụng sự xuất hiện và mức độ đặc trưng của từ ngữ để xếp hạng tài liệu. Vai trò của BM25 trong PE-GH có hai mặt: cung cấp một danh sách kết quả có chi phí thấp và tạo ra thông tin ban đầu cho quyết định có sử dụng Dense hay không. Vì vậy, bộ quyết định hoạt động trên bằng chứng của một lần truy xuất đã diễn ra, thay vì chỉ đọc câu hỏi mà chưa biết kho dữ liệu phản hồi thế nào.

Truy xuất Dense chuyển truy vấn và tài liệu thành các biểu diễn ngữ nghĩa để tìm những tài liệu có nội dung gần với truy vấn. Sentence-BERT và DPR là những nghiên cứu tiêu biểu về biểu diễn văn bản phục vụ truy xuất [6, 7], còn nghiên cứu về tìm kiếm tương đồng cung cấp cơ sở cho việc tìm các biểu diễn gần nhau trong kho tài liệu [8]. Thông tin ngữ nghĩa của tài liệu có thể được chuẩn bị trước, nhưng truy vấn mới vẫn cần được mã hóa khi phục vụ. Sự khác biệt về thời điểm phát sinh chi phí này là cơ sở để đặt quyết định trước encoder.

Hybrid kết hợp kết quả từ khóa và Dense để tận dụng hai nguồn bằng chứng. Việc kết hợp có thể dựa trên điểm hoặc thứ hạng, nhưng chất lượng của danh sách cuối còn phụ thuộc encoder, cách kết hợp và dữ liệu. Trong phạm vi PE-GH, nhánh Hybrid là một hành động truy xuất đã được xác định trước. Bộ quyết định lựa chọn có thực hiện hành động đó cho truy vấn đang xét, thay vì đồng thời thay đổi toàn bộ cấu hình Hybrid ở mỗi yêu cầu.

2.2 Dự báo chất lượng và lựa chọn chiến lược truy xuất

Dự báo chất lượng truy xuất, thường được gọi là QPP, tìm cách ước lượng mức hiệu quả của hệ thống khi chưa có nhãn liên quan cho truy vấn đang phục vụ. Các đặc trưng có thể phản ánh bản thân truy vấn trước khi tìm kiếm hoặc danh sách kết quả sau khi truy xuất, tương ứng với hai nhóm dự báo trước và sau truy xuất [9, 10]. Faggioli và cộng sự cho thấy việc chuyển các tín hiệu dự báo từ hệ thống từ khóa sang truy xuất ngữ nghĩa gặp những hạn chế đáng kể [11]. Kết quả này là lời nhắc rằng tín hiệu từ BM25 không mặc nhiên cho biết chính xác lợi ích của một encoder khác.

WIG và nghiên cứu về sự thay đổi mức phù hợp của danh sách kết quả cung cấp những hướng dự báo từ thông tin sau truy xuất [12, 13]. Các công trình này là cơ sở để xem xét tín hiệu BM25, nhưng chưa tự chứng minh tín hiệu đó đủ để quyết định truy vấn nào hưởng lợi từ Dense.

PE-GH sử dụng dự báo để ra quyết định, nên cần phân biệt chất lượng của đại lượng được dự đoán với chất lượng của hành động sau quyết định. Nếu mô hình nhận biết tốt BM25 thất bại, nó vẫn có thể chuyển một truy vấn sang Dense mà không thu được tài liệu liên quan. Nguyên nhân có thể là nhánh Dense cũng không phù hợp với truy vấn đó. Ngược lại, việc dự báo BM25 chưa hoàn hảo không có nghĩa mọi quyết định tương ứng đều làm mất chất lượng, bởi hai nhánh đôi khi cho cùng chất lượng.

Sự phân biệt này dẫn đến hai tầng đánh giá. AUC cho biết khả năng nhận biết rủi ro BM25, còn nDCG@10 phản ánh chất lượng danh sách cuối đối với người dùng. Báo cáo giữ chất lượng truy xuất làm tiêu chí chính, bởi dự báo tốt hơn chưa đủ để kết luận lựa chọn nhánh hữu ích hơn.

Thời điểm quyết định xác định phần chi phí có thể tránh được. Lựa chọn trước encoder cho phép bỏ qua truy xuất ngữ nghĩa đối với một số truy vấn, nhưng phải chấp nhận chưa biết nhánh này sẽ mang lại kết quả gì. PE-GH xem xét sự đánh đổi đó bằng chất lượng cuối cùng và chi phí thực tế khi các phương pháp được sử dụng cùng ngân sách.

2.3 Các nghiên cứu liên quan trực tiếp

2.3.1 Lựa chọn chiến lược bằng mô hình học

Arabzadeh, Yan và Clarke nghiên cứu lựa chọn từ khóa, Dense hoặc Hybrid theo từng truy vấn nhằm điều chỉnh quan hệ hiệu quả và chi phí. Công trình khảo sát bộ phân loại trên MS MARCO và sử dụng dự báo khả năng thành công của truy xuất từ khóa làm một cơ sở lựa chọn [4]. Vì vậy, ý tưởng quyết định có dùng Dense trước khi chạy nhánh đó đã có tiền lệ trực tiếp.

Đối với PE-GH, bài học cần kế thừa là đánh giá toàn bộ điểm vận hành, trong đó chất lượng và chi phí cùng phụ thuộc chính sách. Câu hỏi của nhóm không dừng ở việc mô hình có phân loại được truy vấn hay không. Bộ quyết định phải đủ rẻ để phần chi phí của chính nó không làm mất ý nghĩa của lựa chọn. Đây là lý do báo cáo xem chi phí đầu cuối và các đối chứng đơn giản là thành phần cần thiết của bằng chứng, thay vì chỉ sử dụng một chỉ số dự báo.

LiteGator nghiên cứu lựa chọn phương pháp truy xuất trong điều kiện tài nguyên hạn chế. Công trình nhấn mạnh một bộ quyết định có chi phí thấp và có thể sử dụng cùng các phương pháp truy xuất đã có [14]. Hướng tiếp cận này gần PE-GH về mục tiêu tiết kiệm, nên cần được đối chiếu để xem cách lựa chọn của nhóm đem lại giá trị bổ sung đến đâu.

Khi so các bộ quyết định trên hạ tầng của nhóm, điều được quan sát là tác động của một phiên bản điều chỉnh cho cùng bài toán và cùng nhánh truy xuất. Kết quả đó không đồng nghĩa đã tái lập toàn bộ thiết lập của công trình gốc. Khác biệt về dữ liệu, mục tiêu nhãn hoặc cách sử dụng ngân sách cần được công bố, vì những yếu tố này có thể ảnh hưởng

chất lượng và chi phí. Chương 4 làm rõ cách đối chiếu cụ thể, còn Chương 5 trình bày cả kết quả thuận lợi và giới hạn của phép so sánh.

ANCE và Contriever tập trung cải thiện khả năng tìm tài liệu liên quan của mô hình truy xuất ngữ nghĩa [15, 16]. Những hướng nghiên cứu này bổ sung cho câu hỏi của PE-GH: một bên nâng chất lượng của phương pháp truy xuất, còn đề tài xác định truy vấn nào cần sử dụng phương pháp đã được lựa chọn.

2.3.2 Kết hợp kết quả và lựa chọn nhánh

Các nghiên cứu về kết hợp kết quả xem xét cách tận dụng đồng thời nhiều nguồn truy xuất. Cormack và cộng sự giới thiệu RRF như một phương pháp hợp nhất danh sách đơn giản [17], còn Bruch và cộng sự phân tích các lựa chọn kết hợp trong truy xuất lai [18]. Những công trình này cho thấy bản thân cách tạo danh sách Hybrid cũng cần được đánh giá. Chúng cung cấp cơ sở để lựa chọn một đối chứng phù hợp, không chứng minh một cách kết hợp luôn tốt hơn trên mọi dữ liệu.

ColBERT, ColBERTv2 và SPLADE là những hướng nghiên cứu nâng hiệu quả truy xuất bằng mô hình học [19, 20, 21]. Báo cáo nhắc đến các hướng này để làm rõ bối cảnh phát triển của truy xuất, nhưng không đánh giá chúng như đối chứng. Phạm vi của PE-GH là quyết định khi nào sử dụng thêm nhánh ngữ nghĩa đã chọn.

Chọn nhánh và chọn cách kết hợp giải quyết hai quyết định khác nhau. Khi cả hai danh sách đã có, việc kết hợp có thể thay đổi thứ tự tài liệu để tận dụng thông tin bổ sung. Bộ quyết định của PE-GH lại xem xét có cần tạo thêm danh sách Dense cho truy vấn hiện tại hay không. Sự khác biệt này có ý nghĩa đối với chi phí: cải thiện thứ tự sau khi đã chạy Dense chưa trực tiếp cho biết liệu có thể bỏ qua phần truy xuất đó mà vẫn giữ chất lượng trong giới hạn cho phép.

Chất lượng của nhánh Hybrid còn đặt giới hạn cho việc đánh giá bộ quyết định. Nếu Dense không mang lại lợi ích trên tập dữ liệu, một chính sách gần như luôn dùng BM25 có thể tiết kiệm nhiều nhưng không chứng minh được khả năng lựa chọn tinh tế. Nếu Hybrid cải thiện đáng kể, giữ chất lượng của nó sẽ đòi hỏi sử dụng nhánh đắt thường xuyên hơn. Vì vậy, báo cáo giữ cả BM25, Dense và luôn chạy Hybrid để cho người đọc thấy mức khó thực tế của bài toán lựa chọn.

2.3.3 Đánh giá đa miền và điều kiện suy rộng

BEIR đặt trọng tâm vào đánh giá truy xuất trên các bộ dữ liệu không đồng nhất, qua đó nhấn mạnh giới hạn của kết quả trong một môi trường hẹp [2]. CQADupStack cung cấp nhiều cộng đồng với đặc điểm từ ngữ và quan hệ câu hỏi khác nhau [1]. Hai nguồn này tạo cơ sở cho việc đánh giá theo miền, đồng thời không biến mười hai chủ đề trong cùng một bộ dữ liệu thành bằng chứng thay thế cho kiểm chứng ngoài bộ dữ liệu đó. Công

trình tài nguyên BEIR của Kamalloo và cộng sự nhấn mạnh nhu cầu có baseline tái lập được và phân tích khác biệt giữa các tập dữ liệu khi diễn giải điểm tổng hợp [22].

Trong PE-GH, sự phân chia giữa miền phát triển và miền xác nhận có ý nghĩa phương pháp rõ ràng. Nếu bộ quyết định chỉ được đánh giá trên miền đã tham gia chọn mô hình, kết quả có thể phản ánh mức thích nghi với các lựa chọn nghiên cứu trước đó. Giữ lại những miền chưa tham gia lựa chọn tại thời điểm đóng băng giúp kiểm tra liệu cấu hình đã chọn có tiếp tục hữu ích trong phạm vi mới. Tuy nhiên, mọi miền cuối cùng vẫn thuộc CQADupStack và dùng cùng một loại nhiệm vụ, nên phạm vi suy rộng còn hữu hạn.

2.4 Định vị hướng tiếp cận của nhóm

Bảng 2.1: Vai trò của các hướng nghiên cứu đối với câu hỏi của PE-GH.

Hướng	**Vấn đề được giải quyết**	**Điều cần kiểm chứng trong PE-GH**
Lựa chọn chiến lược	Chọn từ khóa, Dense hoặc Hybrid cho từng truy vấn.	Bộ quyết định nhẹ có hơn quy tắc đơn giản khi cùng ngân sách hay không.
QPP	Dự báo hiệu quả truy xuất khi chưa có nhãn tại thời điểm phục vụ.	Tín hiệu dự báo BM25 có chuyển thành chất lượng của quyết định dùng Dense hay không.
Kết hợp kết quả	Kết hợp hai danh sách để cải thiện thứ hạng.	Mốc Hybrid có đủ mạnh, và bỏ qua nó làm mất bao nhiêu chất lượng.
Đánh giá đa miền	Xem xét sự thay đổi hiệu quả theo dữ liệu.	Mô hình đóng băng có tiếp tục hữu ích trên các miền xác nhận hay không.

Từ đối chiếu trên, vị trí của đề tài nằm ở một cấu hình lựa chọn có ràng buộc rõ. BM25 được chạy trước; bộ quyết định chỉ sử dụng thông tin có sẵn ở thời điểm đó; nhánh Dense dùng encoder cố định; hiệu quả được đánh giá bằng chất lượng và chi phí đo thật. Việc giữ ràng buộc này làm giảm không gian thiết kế, nhưng giúp xác định bằng chứng nào thực sự hỗ trợ mục tiêu tiết kiệm chi phí trước encoder.

Tính mới cần được hiểu trong phạm vi những gì nhóm đã xây dựng và kiểm chứng. Báo cáo không khẳng định định tuyến từ khóa và ngữ nghĩa là ý tưởng mới. Giá trị nghiên cứu nằm ở việc đặt nhãn học phù hợp với thông tin quan sát được, kiểm tra một bộ quyết định nhẹ bằng đối chứng cùng ngân sách và xác nhận cấu hình đã đóng băng trên các miền chưa dùng để lựa chọn. Độ lớn của hiệu ứng, chi phí của bộ quyết định và các kết quả không đạt kỳ vọng đều phải được giữ trong kết luận.

Phần tiếp theo trình bày cách PE-GH giải quyết yêu cầu lựa chọn trước khi phát sinh chi phí ngữ nghĩa. Nội dung tập trung vào vai trò của thông tin BM25, mục tiêu dự báo và ngân sách sử dụng Dense. Ba yếu tố này nối vấn đề chất lượng và chi phí với những phép kiểm chứng được trình bày ở các chương sau.

Chương 3

Phương pháp PE-GH

3.1 Bài toán và mục tiêu lựa chọn truy vấn

PE-GH xem mỗi truy vấn là một quyết định sử dụng tài nguyên. Sau khi có kết quả BM25, hệ thống lựa chọn trả về kết quả từ nhánh chi phí thấp P^* hoặc thực hiện thêm nhánh Hybrid H^*. Cả hai nhánh đều trả một danh sách câu hỏi từ cùng kho dữ liệu. Khác biệt chính là H^* phải mã hóa truy vấn mới và tìm kiếm Dense, còn P^* sử dụng thông tin đã chuẩn bị trước để xử lý danh sách ứng viên BM25.

Chất lượng của mỗi nhánh được xác định bằng mức độ liên quan của danh sách câu hỏi mà nhánh đó trả về. Khi phục vụ một truy vấn mới, hệ thống chưa biết trước danh sách nào tốt hơn. Bộ quyết định vì thế phải lựa chọn dựa trên thông tin đang có, còn hiệu quả của lựa chọn chỉ được kiểm tra khi đánh giá bằng nhãn liên quan. Đây là nguồn bất định cốt lõi của bài toán, đồng thời giải thích vì sao một bộ quyết định hữu ích vẫn có thể mắc lỗi.

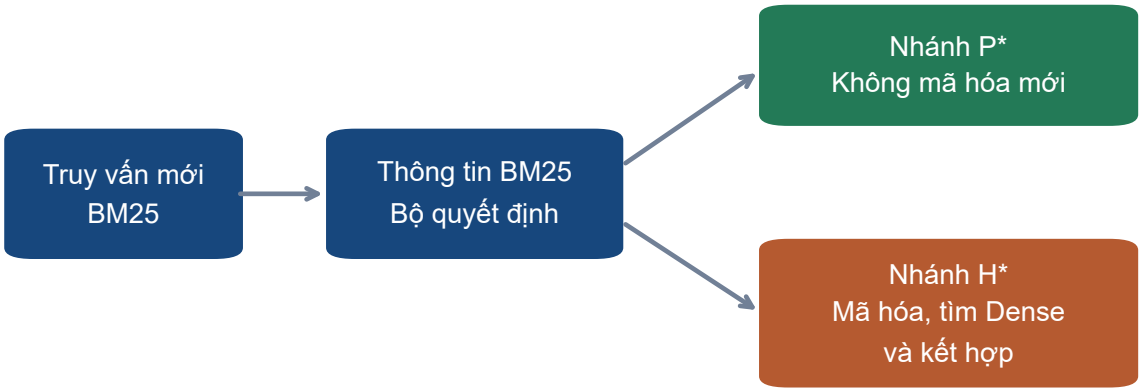
Đề tài theo đuổi hai mục tiêu có quan hệ nhưng không đồng nhất. Mục tiêu thứ nhất là chọn những truy vấn cần nhánh đắt tốt hơn một chính sách đơn giản khi giữ cùng số lượt sử dụng Dense. Mục tiêu thứ hai là chọn một điểm vận hành có ít lượt Dense hơn luôn chạy Hybrid nhưng vẫn giữ chất lượng trong biên cho phép. Mục tiêu thứ nhất đánh giá khả năng lựa chọn; mục tiêu thứ hai đánh giá một cách sử dụng cụ thể của cả hệ thống.

Ngân sách được hiểu là tỷ lệ truy vấn dự kiến sử dụng thêm Dense. Báo cáo phân biệt hai cách đánh giá: so sánh các phương pháp khi chúng dùng đúng cùng số lượt Dense và quan sát hệ thống phục vụ truy vấn theo một chính sách đã chốt. Cách thứ nhất kiểm tra khả năng ưu tiên truy vấn, còn cách thứ hai cho thấy chất lượng và chi phí thực tế tại một điểm vận hành. Hai cách có thể tạo ra tỷ lệ sử dụng Dense hơi khác nhau, nên kết quả được trình bày riêng.

3.2 Nguyên lý hoạt động của PE-GH

PE-GH bắt đầu bằng BM25 để có một danh sách kết quả ban đầu và thông tin về mức độ đáp ứng của kho câu hỏi. Bộ quyết định dựa vào truy vấn cùng danh sách này để xác định có cần sử dụng thêm Dense hay không. Nếu không cần, hệ thống trả kết quả từ nhánh chi phí thấp P^*. Nếu cần, hệ thống thực hiện truy xuất ngữ nghĩa rồi kết hợp với BM25 để tạo kết quả Hybrid H^*.

Trong hệ thống cuối, nhánh chi phí thấp P^* sử dụng danh sách BM25 cùng thông tin ngữ nghĩa đã chuẩn bị trước để điều chỉnh thứ tự kết quả. Nhánh này vẫn phát sinh thêm chi phí so với trả trực tiếp BM25, nhưng không cần mã hóa truy vấn mới. Vì vậy, gọi P^* là



Hình 3.1: Nguyên lý lựa chọn của PE-GH. Bộ quyết định lựa chọn có sử dụng thêm truy xuất ngữ nghĩa trước khi mã hóa truy vấn mới.

nhánh chi phí thấp mang ý nghĩa so sánh với Hybrid, không có nghĩa mọi công việc xử lý sau BM25 đều được loại bỏ.

Nhánh H^* sử dụng thêm Dense rồi kết hợp với kết quả BM25. Mô hình ngữ nghĩa và cách kết hợp được lựa chọn trong giai đoạn phát triển, sau đó giữ cố định khi đánh giá sáu miền xác nhận. Các bộ quyết định trong phép so sánh cùng sử dụng hai nhánh này. Điều kiện đó giúp làm rõ ảnh hưởng của việc chọn truy vấn, thay vì để khác biệt về chất lượng nhánh truy xuất chi phối kết luận.

Đặt quyết định ở vị trí này có một hệ quả trực tiếp: truy vấn bị bỏ qua Dense tránh được cả mã hóa truy vấn và tìm kiếm vector. Tuy nhiên, truy vấn được chuyển sang H^* vẫn phải trả chi phí BM25, bộ quyết định và nhánh Dense. Do đó, phần tiết kiệm kỳ vọng xuất hiện nhờ một tỷ lệ truy vấn kết thúc ở nhánh rẻ. Nếu tỷ lệ đó quá nhỏ hoặc nhánh rẻ quá tốn kém, hiệu quả đầu cuối có thể hạn chế dù lựa chọn không làm giảm nhiều chất lượng.

3.3 Thông tin dùng cho quyết định

Bộ quyết định v2 sử dụng thông tin về nội dung truy vấn, mức độ phù hợp của từ ngữ với kho câu hỏi và biểu hiện của danh sách BM25. Những thông tin này đều có sẵn trước khi chạy Dense. Ràng buộc đó là điều kiện để PE-GH có thể lựa chọn sử dụng truy xuất ngữ nghĩa trước khi phát sinh chi phí của nhánh này.

Các nhóm trong Bảng 3.1 không được diễn giải thành quy luật chắc chắn cho từng truy vấn. Chẳng hạn, khoảng cách điểm lớn có thể biểu thị một kết quả nổi bật, nhưng kết quả nổi bật vẫn có thể không liên quan. Bộ quyết định học mối liên hệ thống kê giữa những tín hiệu này và nhãn BM25 thất bại trên dữ liệu phát triển. Vì thế, ý nghĩa của một đặc

Bảng 3.1: Nhóm thông tin dùng cho bộ quyết định và ý nghĩa đối với bài toán.

Nhóm thông tin	**Ví dụ tín hiệu**	**Câu hỏi mà tín hiệu hỗ trợ**
Đặc điểm truy vấn	Cách diễn đạt và mức độ cụ thể của từ ngữ.	Truy vấn chứa những dấu hiệu nào về nhu cầu tìm kiếm?
Quan hệ với kho câu hỏi	Mức độ xuất hiện của từ ngữ truy vấn trong dữ liệu.	Kho câu hỏi có bao phủ cách diễn đạt của truy vấn hay không?
Danh sách BM25	Mức nổi bật của các kết quả đầu và sự khác biệt giữa chúng.	Kết quả từ khóa có tạo ra bằng chứng rõ về mức độ liên quan hay không?
Dự báo chất lượng	Các dấu hiệu về mức độ chắc chắn của kết quả từ khóa.	Truy vấn có nguy cơ không được BM25 đáp ứng hay không?

trưng nằm trong tổ hợp thông tin và phạm vi đã học, không phải ở một điều kiện đơn lẻ luôn đúng.

Mức phổ biến từ ngữ và đặc điểm kết quả tìm kiếm khác nhau giữa các miền. Khi áp dụng ở miền xác nhận, hệ thống được tiếp cận một tập truy vấn không có nhãn để thích nghi với khác biệt đó, nhưng không học lại bộ quyết định bằng nhãn liên quan của miền này. Do đó, kết quả chuyển miền cần được hiểu trong điều kiện có sẵn truy vấn đại diện. Báo cáo không xem đây là bằng chứng cho trường hợp triển khai ngay ở một miền hoàn toàn chưa có dữ liệu.

Việc sử dụng nhiều thông tin hơn cần được đánh giá bằng đóng góp thực tế đối với chất lượng lựa chọn. Một bộ quyết định phức tạp hơn chưa chắc giúp tìm được câu hỏi phù hợp hơn. Các phân tích ở chương kết quả vì thế tập trung vào hiệu quả cuối cùng, đồng thời xem xét liệu thay đổi mục tiêu dự báo có phù hợp với thông tin mà hệ thống đang quan sát hay không.

3.4 Cơ sở lựa chọn cách học cho bộ quyết định

Phiên bản đầu của PE-GH dự đoán lợi ích khi thay BM25 bằng Hybrid. Nhãn này gần mục tiêu hành động, nhưng phụ thuộc kết quả của cả hai nhánh, trong khi bộ quyết định chỉ quan sát phía BM25. Khi Dense yếu hoặc phản ứng của encoder không được các đặc trưng từ khóa phản ánh tốt, bài toán dự đoán lợi ích có thể khó hơn kỳ vọng. Các vòng đầu chưa cho bằng chứng đủ mạnh rằng mô hình học theo hướng đó vượt quy tắc margin ở cùng ngân sách.

Hệ thống v2 chuyển sang nhận biết trường hợp BM25 không tìm được tài liệu liên quan trong mười kết quả đầu. Bộ quyết định học từ những truy vấn đã có nhãn để ưu tiên sử dụng thêm Dense khi xuất hiện dấu hiệu của tình huống này. Mục tiêu dự báo gắn trực tiếp với chất lượng của danh sách BM25 mà hệ thống quan sát được, nên phù hợp hơn với nguồn thông tin có sẵn trước khi chạy Dense.

Lý do dùng bộ quyết định nhẹ xuất phát từ chính mục tiêu tiết kiệm. Nếu việc lựa chọn tốn gần bằng phần truy xuất có thể bỏ qua, hệ thống khó thu được lợi ích về thời gian

xử lý. Vì vậy, PE-GH ưu tiên một cách dự báo có chi phí thấp, đủ để sắp thứ tự truy vấn theo mức cần hỗ trợ. Giá trị của lựa chọn này được kiểm tra bằng cả chất lượng danh sách cuối và chi phí phục vụ thực tế.

Việc huấn luyện gộp sáu miền hướng đến nhận biết tín hiệu vượt ra ngoài một chủ đề cụ thể. Trong phát triển, mỗi miền được lần lượt để riêng để kiểm tra mô hình học trên các miền còn lại. Sau khi lựa chọn cấu hình, bộ quyết định được học trên cả sáu miền phát triển rồi đóng băng. Quy trình này giảm yêu cầu phải có nhãn của từng miền xác nhận, đồng thời cho phép đánh giá một mô hình cố định trong phạm vi rộng hơn bản đầu.

Tuy vậy, nhận biết BM25 thất bại chưa đồng nghĩa nhận biết đúng truy vấn được Hybrid cải thiện nhiều nhất. Dense cũng có thể không tìm được kết quả phù hợp cho một truy vấn khó, còn truy vấn đã có kết quả từ khóa liên quan vẫn có thể hưởng lợi từ Hybrid. Vì vậy, báo cáo sử dụng thêm một đối chứng biết trước chất lượng của cả hai nhánh để chỉ ra khoảng cách giữa lựa chọn hiện tại và lựa chọn lý tưởng.

Sự thay đổi đồng thời về nhãn, dữ liệu huấn luyện, encoder và nhánh truy xuất cũng giới hạn cách giải thích tiến bộ giữa hai phiên bản. Kết quả v2 tốt hơn v1 có thể cho thấy hệ thống cuối phù hợp hơn, nhưng không đủ để tách riêng tác động của từng lựa chọn. Những nhận định về nguyên nhân chỉ được đưa ra theo mức bằng chứng mà các thí nghiệm đối chứng thực sự hỗ trợ.

3.5 Vai trò của ngân sách truy xuất

Ngân sách giúp thể hiện mục tiêu sử dụng Dense một cách trực tiếp. Với ngân sách thấp, hệ thống ưu tiên một phần nhỏ truy vấn có điểm quyết định cao. Với ngân sách cao, nhiều truy vấn được chuyển sang Hybrid hơn, nên chất lượng thường tiến gần mốc luôn chạy Hybrid trong các kết quả quan sát. Mối liên hệ này cần được xem bằng đường cong thay vì giả định điểm quyết định tương ứng với một mức tiết kiệm thời gian cố định.

Trong so sánh cùng ngân sách, các bộ quyết định được cấp cùng số lượt Dense trên mỗi phần dữ liệu đánh giá. Chúng lựa chọn bằng điểm dự báo, không dùng nhãn liên quan của truy vấn đang được đánh giá. Kết quả vì thế cho biết phương pháp nào ưu tiên truy vấn hữu ích hơn khi có cùng mức tài nguyên. Tuy nhiên, phép so sánh trên một tập truy vấn đã xác định chưa bảo đảm hệ thống phục vụ liên tiếp sẽ luôn đạt đúng tỷ lệ đó.

Ở điểm vận hành, chính sách lựa chọn được xác định từ những truy vấn chưa có nhãn và giữ cố định trong khi đánh giá. Nếu đặc điểm truy vấn thay đổi, tỷ lệ thực tế sử dụng Dense có thể lệch khỏi ngân sách dự kiến. Những truy vấn mà BM25 không cung cấp được tín hiệu từ khóa cũng cần được chuyển sang Dense. Vì vậy, ngân sách là mục tiêu phân bổ tài nguyên, còn tỷ lệ quan sát phải được báo cáo cùng chất lượng và thời gian xử lý.

Ngân sách vận hành 80% được chọn trong giai đoạn phát triển theo mục tiêu giảm số lượt Dense mà vẫn giữ chất lượng gần Hybrid. Tiêu chí lựa chọn khi đó chỉ chấp nhận

mức giảm không quá 0,005. Sau khi chốt điểm vận hành, giai đoạn xác nhận sử dụng biên suy giảm 0,01 để kiểm tra trên các miền khác. Hai giá trị phục vụ hai vai trò khác nhau: một giá trị dùng để chọn phương án, còn giá trị kia dùng để kết luận trên dữ liệu xác nhận.

3.6 Quá trình hình thành phương pháp cuối

Bảng 3.2: Các bước phát triển dẫn đến PE-GH v2.

Giai đoạn	Cách tiếp cận chính	Bài học cho hệ thống cuối
PE-GH v1	Dự đoán lợi ích Hybrid từ dữ liệu của từng miền.	Có thể giảm chi phí, nhưng chưa cho thấy lựa chọn tốt hơn margin khi cùng ngân sách.
Vòng v3	Xem xét các phương án truy xuất có chi phí thấp hơn.	Cần giữ đối chứng từ khóa mạnh và kiểm tra quan hệ giữa tín hiệu BM25 với lợi ích Dense.
PE-GH v2 trong vòng v4	Dự báo BM25 thất bại và học từ nhiều miền.	Xác nhận phương pháp đã chốt trên sáu miền chưa dùng để lựa chọn.

Nguồn: Tổng hợp từ các vòng thực nghiệm của nhóm.

Quá trình ở Bảng 3.2 cho thấy kết quả chưa đạt kỳ vọng có vai trò trong việc thu hẹp câu hỏi nghiên cứu. Vấn đề không còn là xây một bộ quyết định bất kỳ để bỏ qua Dense, mà là tìm một cách học phù hợp với thông tin sẵn có và kiểm chứng nó trước một quy tắc đơn giản. Những phương án tiết kiệm khác cũng được giữ trong đánh giá để xác định lựa chọn truy vấn có giá trị ở điều kiện nào.

Hệ thống cuối giữ cấu trúc quyết định trước encoder nhưng thay đổi những yếu tố ảnh hưởng trực tiếp đến chất lượng hai nhánh và khả năng dự báo. Báo cáo vì vậy đánh giá cả hệ thống và khả năng lựa chọn trong cùng một khung đối chứng. Chương tiếp theo mô tả cách tổ chức dữ liệu và phép so sánh để các kết luận về hai mức này không bị trộn lẫn.

Chương 4
Tổ chức và tiêu chí thực nghiệm

4.1 Dữ liệu và phạm vi đánh giá

Thực nghiệm sử dụng CQADupStack với nhiệm vụ tìm những câu hỏi có quan hệ liên quan hoặc trùng lặp với truy vấn. Mỗi miền có kho câu hỏi riêng, tập truy vấn và nhãn liên quan tương ứng. Kho dữ liệu có sẵn khi truy xuất, còn nhãn được dùng theo vai trò huấn luyện hoặc đánh giá đã xác định. Việc cho hệ thống tiếp cận kho câu hỏi không đồng nghĩa cho phép sử dụng nhãn test để chọn cấu hình.

Toàn bộ quá trình đã sử dụng mười hai miền theo những vai trò khác nhau. Programmers và Unix được dùng trong giai đoạn đầu. Android, GIS, Mathematica và Webmasters được bổ sung trong vòng v3. Sáu miền này trở thành dữ liệu phát triển và huấn luyện của hệ cuối. English, Gaming, Physics, Stats, TeX và WordPress được giữ lại cho giai đoạn xác nhận v2 tại thời điểm chốt giao thức. Số lượng dữ liệu và vai trò được tổng hợp trong Bảng 4.1.

Bảng 4.1: Phạm vi dữ liệu trong các phép đánh giá của hệ cuối.

Vai trò	Các miền	Truy vấn	Tài liệu
Phát triển và huấn luyện	Programmers, Unix, Android, GIS, Mathematica, Webmasters	4.842	174.303
Xác nhận chất lượng	English, Gaming, Physics, Stats, TeX, WordPress	8.303	282.896
Đo online	Programmers, Unix	1.948	79.558

Nguồn: Thực nghiệm của nhóm; tập online là một phần của nhóm miền phát triển.

Các phương pháp được đánh giá trên cùng phiên bản dữ liệu và nhãn liên quan, với cách xử lý câu hỏi nhất quán. Kết quả không bao gồm chính câu hỏi đang làm truy vấn. Đối chứng BM25 cũng được giữ cố định, bởi những khác biệt trong cách áp dụng BM25 có thể ảnh hưởng phép so sánh [23]. Những điều kiện chung này giúp kết quả phản ánh khác biệt giữa các phương pháp trên cùng một bài toán.

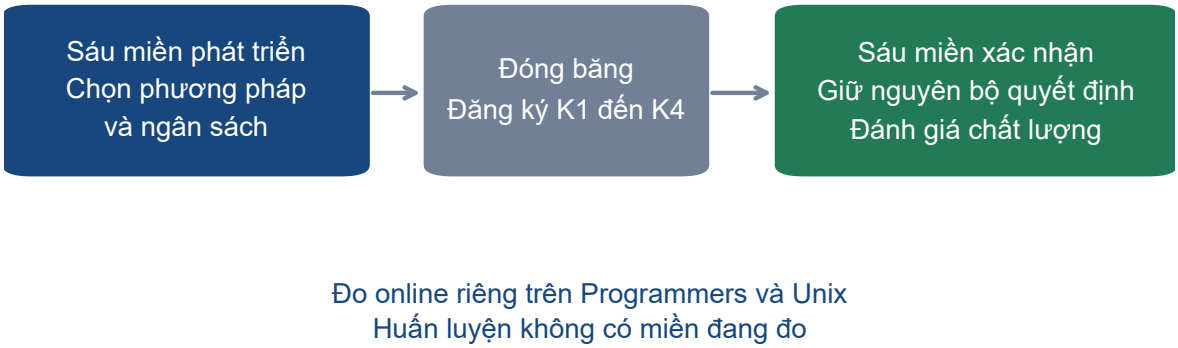
Cách gọi sáu miền xác nhận là “mới” mang ý nghĩa lịch sử tại thời điểm đóng băng. Sau khi thực nghiệm kết thúc, tất cả mười hai miền đã được xem xét trong quá trình nghiên cứu. Nếu nhóm tiếp tục đổi thuật toán dựa trên các kết quả này, sáu miền đó không còn là tập xác nhận chưa dùng cho lựa chọn mới. Phân biệt này cần thiết để không mở rộng mức bằng chứng của giao thức ban đầu sang một phiên bản tiếp theo.

4.2 Phân chia dữ liệu và quy trình nghiên cứu

Các truy vấn được chia thành năm phần, trong đó những câu hỏi có quan hệ gần được giữ cùng nhóm. Các phần dữ liệu lần lượt đảm nhận vai trò học, lựa chọn phương án và đánh giá; mỗi truy vấn được đánh giá đúng một lần trên phần dành riêng cho nó. Cách tổ chức này nhằm hạn chế việc các câu hỏi quá giống nhau xuất hiện ở cả phía phát triển và phía đánh giá, từ đó làm kết quả tốt hơn khả năng áp dụng thực tế.

Trong phát triển v2, nhóm lần lượt giữ riêng từng miền để xem bộ quyết định học từ các miền còn lại có tiếp tục hữu ích hay không. Kết quả trung bình theo miền được dùng để lựa chọn phương án và ngân sách. Sau đó, bộ quyết định được học trên toàn bộ sáu miền phát triển rồi giữ cố định. Việc giữ riêng miền kiểm tra khả năng áp dụng sang chủ đề khác, còn việc chia truy vấn bên trong mỗi miền giúp tách các vai trò sử dụng dữ liệu.

Mô hình ngữ nghĩa được lựa chọn trên Programmers và Unix theo chất lượng Hybrid, đồng thời cân nhắc chi phí khi các phương án đạt chất lượng gần nhau. Phương pháp truy xuất, cách học của bộ quyết định, ngân sách so khớp 50% và ngân sách vận hành 80% đều được chốt từ giai đoạn phát triển. Nhãn của sáu miền xác nhận không được sử dụng để lựa chọn lại những yếu tố này.



Hình 4.1: Quan hệ giữa phát triển, đóng băng và xác nhận. Nhánh online trên Programmers/Unix sử dụng mô hình được học không có miền đang đo, nên giữ vai trò riêng với xác nhận chất lượng trên sáu miền mới.

Giao thức xác nhận được ghi nhận trước khi thu thập dữ liệu của sáu miền giữ lại. Hồ sơ chốt phương pháp, ngân sách và bốn giả thuyết K1 đến K4. Việc đăng ký không làm mất các giới hạn của nghiên cứu, nhưng giúp phân biệt kết quả kiểm chứng giả thuyết có trước với những nhận xét được hình thành sau khi đã biết số liệu.

Trên miền xác nhận, bộ quyết định v2 được giữ nguyên nhưng hệ thống có sử dụng truy vấn không nhãn để thích nghi với đặc điểm của miền và xác định chính sách vận hành.

Đây là một điều kiện của phép đánh giá. Vì vậy, báo cáo phân biệt việc không dùng nhãn miền xác nhận để học lại mô hình với việc hoàn toàn chưa tiếp cận dữ liệu của miền đó.

4.3 Các phương pháp đối chứng

Đối chứng được tổ chức theo câu hỏi nghiên cứu. BM25 và Dense cho thấy chất lượng của từng nguồn truy xuất. P^* cho biết nhánh rẻ thực sự cải thiện được bao nhiêu so với BM25. H^* là mốc chất lượng và chi phí khi luôn sử dụng cả hai nguồn. R^* mã hóa truy vấn nhưng chỉ chấm lại các ứng viên BM25, nên kiểm tra một hướng tiết kiệm khác với bỏ qua encoder.

Để đánh giá khả năng lựa chọn, BM25-margin dùng mức khác biệt giữa các kết quả đầu danh sách làm quy tắc đơn giản không học. Lựa chọn ngẫu nhiên được thực hiện nhiều lần để giảm ảnh hưởng của một lần chọn tình cờ. Đối chứng oracle biết trước nhánh nào mang lại lợi ích lớn hơn cho từng truy vấn. Vì cần nhãn liên quan để đưa ra lựa chọn, oracle chỉ dùng để chỉ ra khoảng cải thiện còn có thể đạt được trong đánh giá, không phải phương pháp phục vụ truy vấn mới.

PE-GH v1 được giữ theo giao thức cũ, sử dụng mô hình ngữ nghĩa MiniLM [24] và được lựa chọn bằng dữ liệu có nhãn trong từng miền. V2 thay đổi cả mô hình ngữ nghĩa, nhánh truy xuất và mục tiêu học. Vì vậy, so sánh v2 với v1 đánh giá mức tiến bộ của toàn hệ thống. Những khác biệt giữa hai phiên bản không cho phép quy toàn bộ chênh lệch kết quả cho riêng bộ quyết định.

Hai đối chứng dựa trên công trình trước được bổ sung sau phân tích chính. Một đối chứng dùng BERT [25] theo hướng lựa chọn của Arabzadeh, còn đối chứng LiteGator đại diện cho cách ra quyết định có chi phí thấp. Cả hai được điều chỉnh để cùng lựa chọn giữa P^* và H^* trên dữ liệu của đề tài. Những điều chỉnh về nhiệm vụ và mục tiêu dự báo thuộc cách áp dụng của nhóm, nên phần đối chiếu được xem là thăm dò, không phải tái lập nguyên vẹn kết quả công bố của hai bài báo.

Trong so khớp ngân sách, mọi bộ quyết định được dùng đúng cùng số lượt Dense trên mỗi phần dữ liệu và mỗi miền. Trong phép đo chi phí thăm dò, mô hình được lựa chọn mà không dùng miền đang đo. Những điều kiện chung về nhánh, dữ liệu và ngân sách giúp phép so sánh nhất quán hơn. Tuy nhiên, BERT chưa được khảo sát nhiều phương án như hai bộ quyết định nhẹ do chi phí phát triển cao hơn, nên kết quả vẫn có giới hạn về mức độ cân bằng giữa các đối chứng.

4.4 Thước đo và nguyên tắc kiểm định

Chất lượng chính được đo bằng nDCG@10 [26]. Thước đo phản ánh việc đưa các tài liệu liên quan lên những vị trí đầu, là phần danh sách có ý nghĩa trực tiếp đối với người dùng. Điểm tổng hợp chính là trung bình macro theo miền: trước hết tính trung bình truy

vấn trong từng miền, sau đó lấy trung bình các miền với trọng số bằng nhau. Cách tổng hợp này tránh để miền TeX có nhiều truy vấn quyết định phần lớn kết quả gộp.

Các so sánh chất lượng được thực hiện trên cùng truy vấn để hạn chế ảnh hưởng của khác biệt dữ liệu [27, 28]. Khoảng tin cậy được ước lượng bằng lấy mẫu lại, có xét các nhóm truy vấn và vai trò ngang nhau của từng miền. Khoảng này mô tả bất định của kết quả trên dữ liệu đã đánh giá; nó chưa bao gồm đầy đủ biến động từ việc học lại mô hình, lựa chọn phương án hoặc chuyển sang một tập miền hoàn toàn khác.

K1 kiểm tra bộ quyết định v2 tốt hơn BM25-margin ở cùng ngân sách 50%. K2 kiểm tra PE-GH ở ngân sách vận hành 80% không kém H^* quá 0,01. K3 kiểm tra v2 tốt hơn v1 ở mức toàn hệ thống. K4 kiểm tra v2 tốt hơn lựa chọn ngẫu nhiên ở cùng ngân sách 50%. Bốn phép kiểm định sử dụng p-value một phía và hiệu chỉnh Holm [29] với mức sai lầm toàn họ 0,05 theo giao thức đã đăng ký.

Với K2, kết luận không kém được chấp nhận khi bằng chứng thống kê cho thấy mức suy giảm chất lượng chưa vượt biên 0,01 đã xác định trước. Tiêu chí này cho phép một mất mát nhỏ, nên không đồng nghĩa hai phương pháp có chất lượng bằng nhau. Trong những so sánh thông thường khác, khoảng tin cậy chứa 0 chỉ cho biết chưa phát hiện khác biệt có ý nghĩa thống kê theo cách đánh giá đang dùng; điều đó cũng chưa chứng minh hai phương pháp tương đương.

Các đường cong ngân sách, AUC, kết quả từng miền và đối chiếu BERT/LiteGator bổ sung ngữ cảnh cho kết quả chính. Những phân tích ngoài K1 đến K4 được xem là mô tả hoặc thăm dò và không được gán hiệu chỉnh Holm của bốn giả thuyết đã đăng ký.

4.5 Điều kiện đo chi phí truy xuất

Các phương pháp được đo trên cùng một máy sử dụng CPU, trong điều kiện mỗi lần phục vụ một truy vấn và hệ thống đã sẵn sàng hoạt động. Thời gian được tính từ khi bắt đầu xử lý truy vấn đến khi có danh sách kết quả, bao gồm cả chi phí của bộ quyết định và phần truy xuất được lựa chọn. Cách đo này kiểm tra lợi ích thực tế của chính sách, thay vì suy ra thời gian tiết kiệm chỉ từ tỷ lệ bỏ qua Dense.

Phép đo chính bao gồm 97.400 yêu cầu trên 1.948 truy vấn, còn phiên đối chiếu thăm dò bao gồm 126.620 yêu cầu. Các phương pháp trong từng phiên dùng cùng tập truy vấn và được đo lặp lại để giảm tác động của dao động thời gian xử lý. Kết quả trả về trong lúc đo cũng được đối chiếu với kết quả đánh giá chất lượng để bảo đảm phép so sánh chi phí vẫn gắn với cùng hành vi truy xuất.

Độ trễ trung bình, p95, thời gian CPU và bộ nhớ đỉnh được báo cáo cùng tỷ lệ Dense thực tế. Khoảng tin cậy có xét việc cùng một truy vấn được đo nhiều lần. Mức giảm chi phí chỉ được tính so với đối chứng trong cùng phiên, nhằm hạn chế ảnh hưởng của khác biệt điều kiện đo.

Chương 5
Kết quả và thảo luận

Chương này đánh giá PE-GH theo những câu hỏi đã đặt ra, đồng thời phân biệt ba phạm vi bằng chứng. Kết quả xác nhận chính sử dụng sáu miền chưa tham gia lựa chọn phương pháp tại thời điểm đăng ký. Phép đo trên Programmers và Unix kiểm tra chất lượng đi kèm chi phí phục vụ truy vấn. Đối chiếu BERT và LiteGator được thực hiện sau đó theo phân tích thăm dò. Các kết quả được trình bày riêng theo phạm vi dữ liệu và điều kiện đánh giá.

5.1 Chất lượng truy xuất trên các miền xác nhận

5.1.1 Mức chất lượng của các lựa chọn truy xuất

Trước khi xem xét bộ quyết định, cần xác định hai nhánh có tạo ra một bài toán lựa chọn đáng kể hay không. Bảng 5.1 cho thấy H^* đạt nDCG@10 trung bình macro 0,4223, cao hơn BM25 0,3267 và Dense độc lập 0,4031. Trong phạm vi này, chạy cả hai nguồn mang lại lợi ích so với chỉ dùng từ khóa hoặc chỉ dùng ngữ nghĩa. Vì vậy, việc bỏ qua Dense có một chi phí chất lượng tiềm tàng thực sự, không chỉ bỏ một nhánh gần như vô ích.

Bảng 5.1: Chất lượng trên sáu miền xác nhận. Dòng vận hành phản ánh chính sách đã chốt, còn dòng so khớp 50% dùng cùng số lượt Dense với các đối chứng lựa chọn truy vấn.

Phương pháp	nDCG@10	Dense (%)
BM25	0,3267	0
P^*	0,3270	0
Dense arctic	0,4031	100
H^*	0,4223	100
PE-GH v2 vận hành	0,4159	80
PE-GH v2 so khớp	0,3933	50
BM25-margin	0,3892	50
Ngẫu nhiên	0,3744	50
PE-GH v1	0,3469	81,8

Nguồn: Thực nghiệm xác nhận của nhóm trên sáu miền CQADupStack.

Nhánh P^* đạt 0,3270, chỉ cao hơn điểm BM25 khoảng 0,0003. Quan sát này cho thấy phần xếp hạng bổ sung trong hệ cuối chưa mang lại cải thiện trung bình đáng kể về mặt độ lớn trên các miền xác nhận. Tuy nhiên, hai giá trị trung bình gần nhau chưa chứng minh hai nhánh tương đương bằng một phép kiểm định. Cách diễn giải phù hợp là lợi ích quan sát của phần xếp hạng bổ sung nhỏ, nên cần cân nhắc phần chi phí mà nó thêm vào nhánh được kỳ vọng là rẻ.

Ở ngân sách vận hành 80%, PE-GH v2 đạt 0,4159, thấp hơn H^* khoảng 0,0064. Chất lượng không được giữ nguyên hoàn toàn, nhưng mức suy giảm nhỏ hơn biên 0,01 mà đề tài chấp nhận trước xác nhận. Đổi lại, tỷ lệ thực tế sử dụng Dense nằm khoảng 79,9% đến 80,2% theo miền. Kết quả này hỗ trợ cách sử dụng PE-GH như một lựa chọn đánh đổi có kiểm soát, thay vì một phương pháp đạt toàn bộ chất lượng Hybrid mà không trả chi phí tương ứng.

Tại ngân sách so khớp 50%, chất lượng PE-GH là 0,3933. Điểm này thấp hơn mức vận hành 80%, nhưng cho phép xem rõ hơn giá trị của thứ tự ưu tiên truy vấn. Với cùng số lượt Dense, BM25-margin đạt 0,3892 và lựa chọn ngẫu nhiên đạt 0,3744. Khoảng chênh lệch với ngẫu nhiên lớn hơn khoảng chênh lệch với margin. Vì vậy, có khả năng lựa chọn hữu ích không đồng nghĩa mô hình học tạo ra một bước tiến lớn so với một quy tắc rẻ đã có tín hiệu tốt.

5.1.2 Sự thay đổi theo miền

Bảng 5.2: Chất lượng theo miền và chênh lệch giữa PE-GH v2 với margin ở cùng ngân sách 50%. Các giá trị là mô tả, chưa phải kiểm định riêng cho từng miền.

Miền	BM25	H^*	V2 (80%)	V2 − margin (50%)
English	0,3375	0,4590	0,4505	0,0014
Gaming	0,4675	0,5863	0,5815	0,0082
Physics	0,3266	0,4388	0,4310	0,0055
Stats	0,2883	0,3624	0,3571	0,0139
Tex	0,2490	0,3185	0,3179	0,0035
Wordpress	0,2914	0,3686	0,3574	-0,0074

Nguồn: Thực nghiệm xác nhận của nhóm; kết quả tổng hợp theo miền.

Bảng 5.2 cho thấy mức chất lượng khác nhau đáng kể giữa các miền. Gaming có điểm Hybrid cao hơn các miền còn lại, trong khi TeX thấp hơn dù chứa nhiều truy vấn hơn. Do báo cáo dùng macro theo miền, sự chênh lệch số truy vấn không làm TeX có trọng số cao hơn Gaming trong kết quả chính. Cách tổng hợp này giữ câu hỏi nghiên cứu ở mức hiệu quả trung bình trên các cộng đồng, thay vì chỉ trên một truy vấn lấy ngẫu nhiên từ tập gộp.

PE-GH v2 hơn margin ở năm trong sáu miền tại 50%. WordPress là ngoại lệ, với chênh lệch khoảng $-0{,}0074$. Stats có mức chênh dương lớn nhất, khoảng 0,0139. Các giá trị này cho biết lợi thế trung bình không phân bố đồng đều và không bảo đảm mọi miền được cải thiện. Do chưa có phép kiểm định riêng đã đăng ký cho từng miền, báo cáo dùng chúng để phân tích sự không đồng nhất, không xem mỗi dấu dương là một phát hiện xác nhận độc lập.

Ở ngân sách 80%, WordPress còn có mức giảm so với H^* khoảng 0,0112, lớn hơn biên 0,01 nếu chỉ nhìn điểm trung bình miền. K2 vẫn là giả thuyết trên macro sáu miền, nên

kết quả đạt K2 không bảo đảm từng miền đều thỏa cùng một biên. Đây là khác biệt có ý nghĩa khi triển khai: một đơn vị vận hành chỉ quan tâm WordPress không thể dùng kết luận macro để bỏ qua mức mất mát riêng của miền đó.

5.2 Kiểm chứng các giả thuyết nghiên cứu

Bảng 5.3: Kết quả K1 đến K4 trên sáu miền xác nhận. Cột khoảng tin cậy dùng hai phía để mô tả, còn quyết định kiểm định dùng p-value một phía và Holm theo giao thức.

Giả thuyết	Chênh lệch	CI hai phía 95%	p một phía	Holm
K1	0,0042	[0,0003; 0,0081]	0,0171	Đạt
K2	-0,0064	[-0,0085; -0,0043]	0,0009	Đạt
K3	0,0690	[0,0629; 0,0752]	$< 0{,}0001$	Đạt
K4	0,0190	[0,0155; 0,0225]	$< 0{,}0001$	Đạt

Nguồn: Thực nghiệm của nhóm; khoảng tin cậy được ước lượng bằng lấy mẫu lại theo nhóm truy vấn.

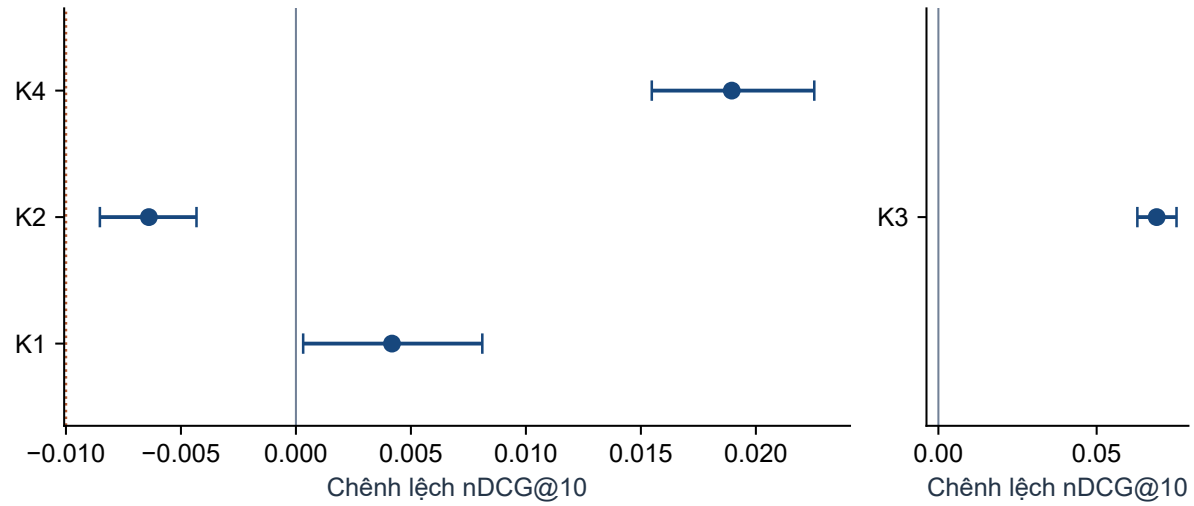
K1 cho chênh lệch PE-GH v2 trừ BM25-margin khoảng 0,0042 tại cùng ngân sách 50%, với khoảng tin cậy hai phía 95% từ 0,0003 đến 0,0081. P-value một phía là 0,0171 và phép kiểm định đạt điều kiện Holm. Kết quả hỗ trợ giả thuyết bộ quyết định học có giá trị riêng trên các miền xác nhận. Tuy nhiên, cận dưới gần 0 và độ lớn cải thiện nhỏ cho thấy cần trình bày hiệu ứng đúng mức, thay vì mô tả như một bước tăng chất lượng lớn.

K2 có chênh lệch so với H^* khoảng $-0{,}0064$. Cận dưới một phía 95% là khoảng $-0{,}00819$, nằm phía trên $-0{,}01$, đồng thời phép kiểm định không kém đạt điều kiện Holm. Kết luận được hỗ trợ là PE-GH ở điểm vận hành giảm số lượt Dense mà không kém mốc Hybrid quá biên đã đăng ký. Khoảng tin cậy hai phía của chênh lệch nằm hoàn toàn dưới 0, nên bằng chứng cũng cho thấy tồn tại một mức giảm chất lượng đo được. Hai nhận định này nhất quán vì mục tiêu không kém cho phép mất mát hữu hạn.

K3 ghi nhận v2 cao hơn v1 khoảng 0,0690, với khoảng tin cậy từ 0,0629 đến 0,0752. Chênh lệch này lớn hơn đáng kể hiệu ứng K1 nhưng thuộc so sánh toàn hệ thống. V2 sử dụng mô hình ngữ nghĩa khác, nhánh truy xuất khác và mục tiêu học khác. Do đó, kết quả cho biết phiên bản cuối phù hợp hơn trong giao thức so sánh đã dùng, chưa chứng minh riêng thay đổi bộ quyết định đã tạo ra toàn bộ cải thiện.

K4 cho mức hơn lựa chọn ngẫu nhiên khoảng 0,0190 tại cùng ngân sách 50%, với khoảng tin cậy từ 0,0155 đến 0,0225. Kết quả này xác nhận bộ quyết định không chỉ đạt chất lượng do phân bổ tài nguyên tùy ý. Đặt cạnh K1, nó cũng cho thấy margin đã khai thác được một phần lớn tín hiệu hữu ích. Giá trị cần đánh giá của mô hình học là phần cải thiện bổ sung trước đối chứng này, không phải toàn bộ khoảng cách từ ngẫu nhiên lên PE-GH.

Cả bốn giả thuyết đạt tiêu chí trong phạm vi xác nhận, nhưng chúng trả lời những câu hỏi khác nhau. K1 và K4 liên quan trực tiếp đến việc lựa chọn truy vấn. K2 đánh giá một



Hình 5.1: Ước lượng và khoảng tin cậy hai phía 95% của K1 đến K4. K3 dùng ô riêng vì độ lớn khác biệt. Đường tại $-0{,}01$ minh họa biên của K2; kết luận K2 dùng cận một phía và kiểm định đã hiệu chỉnh.

điểm vận hành của chính sách. K3 đánh giá mức nâng cấp cả hệ thống. Việc tách vai trò giúp tránh dùng kết quả mạnh của K3 để làm lớn hơn đóng góp riêng của bộ quyết định hoặc dùng K2 để khẳng định chất lượng được giữ nguyên.

5.3 Quan hệ giữa chất lượng và chi phí

5.3.1 Độ trễ đầu cuối và tỷ lệ sử dụng Dense

Bảng 5.4: Phiên online chính trên Programmers và Unix. Mean, p95 và CPU tính bằng ms; RSS là bộ nhớ đỉnh tính bằng MiB. Chất lượng là macro hai miền, khác phạm vi sáu miền của Bảng 5.1.

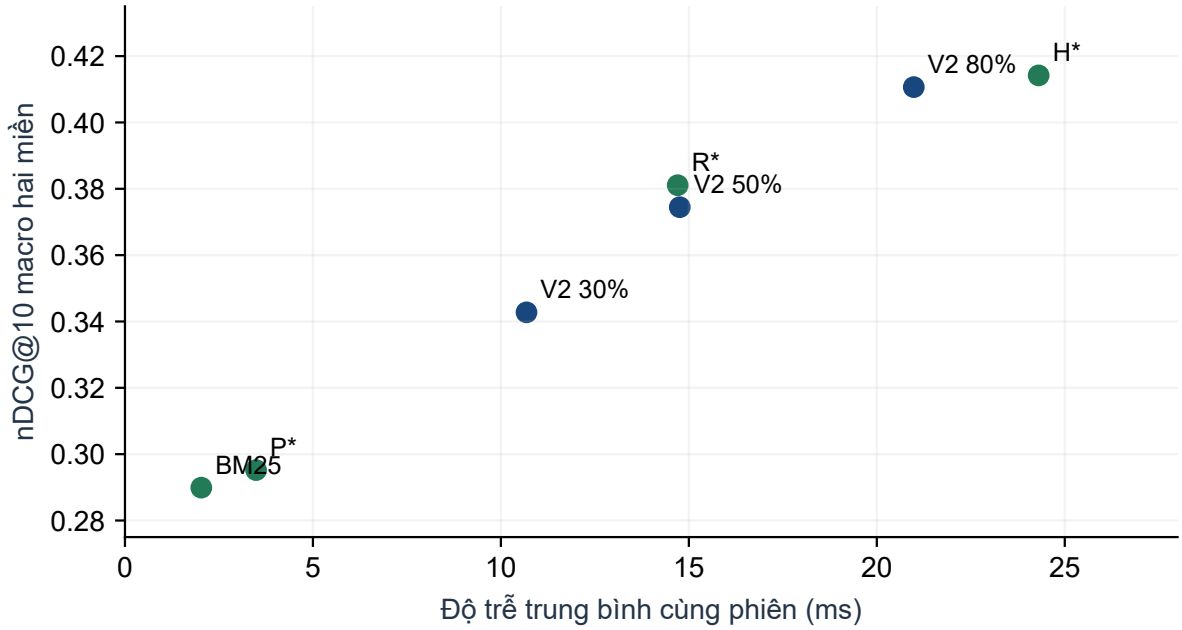
Phương pháp	Mean	p95	CPU	RSS	nDCG@10
BM25	2,03	3,51	2,0	285,4	0,2899
P^*	3,49	5,06	3,5	620,4	0,2952
R^*	14,70	17,66	57,5	654,3	0,3811
H^*	24,31	28,95	90,7	726,0	0,4142
PE-GH v2 (30%)	10,68	26,77	39,3	768,0	0,3428
PE-GH v2 (50%)	14,76	28,14	54,5	769,3	0,3745
PE-GH v2 (80%)	20,98	29,52	78,5	771,3	0,4107

Nguồn: Phiên online chính của nhóm; 9.740 yêu cầu cho mỗi phương pháp.

Trong phiên online chính, H^* có độ trễ trung bình 24,31 ms. PE-GH v2 ở ngân sách 50% đạt 14,76 ms, giảm khoảng 39,3%, với khoảng tin cậy 95% của mức giảm từ 37,5% đến 41,1%. Tỷ lệ Dense thực tế khoảng 50,1%. Số đo xác nhận việc bỏ qua Dense chuyển thành lợi ích thời gian trong điều kiện đã đo, nhưng mức giảm thời gian thấp hơn mức giảm số lượt Dense vì hệ thống vẫn trả chi phí BM25, bộ quyết định và nhánh rẻ.

Ở mức 30%, độ trễ trung bình giảm còn 10,68 ms, đi kèm chất lượng 0,3428. Ở mức 80%, độ trễ là 20,98 ms và chất lượng 0,4107. Những điểm này không nên được xếp thành một kết luận duy nhất rằng ngân sách càng thấp càng tốt. Người vận hành nhận được thời gian thấp hơn bằng cách chấp nhận sử dụng Dense ít hơn, trong khi chất lượng có thể giảm. Ý nghĩa của ngân sách là làm rõ lựa chọn đó, không xóa bỏ đánh đổi.

Điểm 80% có ý nghĩa riêng đối với mục tiêu giữ chất lượng Hybrid. Trong phiên chính, mức giảm độ trễ trung bình so với H^* khoảng 13,7%, nhỏ hơn đáng kể mức 39,3% ở 50%. Vì vậy, không thể ghép kết luận chất lượng của điểm 80% với mức tăng tốc ở 50% để mô tả một hệ thống duy nhất. Trên sáu miền xác nhận, K2 thuộc 80%; trên hai miền online, số đo của mỗi điểm phải đi cùng chất lượng và tỷ lệ Dense tương ứng.



Hình 5.2: Chất lượng và độ trễ trung bình của các phương pháp trong cùng phiên online chính. Các điểm là kết quả quan sát trên hai miền, không phải dự đoán thời gian từ tỷ lệ Dense.

5.3.2 Chi phí hai nhánh và độ trễ đuôi

Lợi ích về độ trễ trung bình xuất hiện khi một phần truy vấn được kết thúc ở nhánh chi phí thấp. Những truy vấn này không cần thực hiện thêm toàn bộ quá trình truy xuất ngữ nghĩa. Tuy nhiên, các truy vấn được chuyển sang Hybrid vẫn phải thực hiện phần công việc có chi phí cao hơn. Vì vậy, thời gian trung bình có thể giảm trong khi thời gian của nhóm yêu cầu chậm nhất thay đổi ít.

p95 của H^* là 28,95 ms, trong khi PE-GH ở 50% là 28,14 ms và ở 80% là 29,52 ms. Không có một xu hướng cải thiện đuôi rõ ràng tương ứng với mức giảm độ trễ trung bình. Những yêu cầu đi nhánh Dense vẫn chịu chi phí mã hóa và tìm vector, cộng thêm

phần quyết định. Khi nhóm yêu cầu chậm nằm chủ yếu ở nhánh này, bỏ qua Dense cho các truy vấn khác không làm p95 giảm nhiều.

Kết quả p95 cũng cho thấy yêu cầu vận hành cần được xác định trước khi chọn phương pháp. Nếu ưu tiên là giảm tổng tài nguyên xử lý hoặc độ trễ trung bình, bỏ qua Dense có thể hữu ích. Nếu ưu tiên là thời gian phản hồi ổn định cho gần như mọi yêu cầu, chỉ thêm bộ quyết định chưa giải quyết được vấn đề. Khi đó, cần cải thiện cả những yêu cầu vẫn sử dụng Dense, thay vì kỳ vọng giảm số lượt sử dụng nhánh này sẽ cải thiện mọi khía cạnh của thời gian phản hồi.

Thời gian CPU trung bình của PE-GH 50% khoảng 54,5 ms, thấp hơn H^* khoảng 90,7 ms trong cùng phiên. Đại lượng này phản ánh tài nguyên xử lý đã sử dụng, còn độ trễ phản ánh thời gian chờ kết quả. Hai góc nhìn cùng hỗ trợ đánh giá lợi ích của phương pháp, nhưng chưa cho biết hệ thống sẽ phục vụ được bao nhiêu yêu cầu khi nhiều người dùng truy cập đồng thời.

Bộ nhớ đỉnh không giảm theo tỷ lệ bỏ qua Dense. Ở 50%, PE-GH dùng khoảng 769 MiB, so với khoảng 726 MiB của H^*. Hệ thống vẫn phải sẵn sàng thực hiện truy xuất ngữ nghĩa khi được lựa chọn và còn sử dụng thêm bộ quyết định. Vì vậy, giảm số lượt Dense không đồng nghĩa giảm nhu cầu bộ nhớ. Kết quả hiện có hỗ trợ lợi ích về thời gian và tài nguyên xử lý, chưa hỗ trợ kết luận tiết kiệm bộ nhớ.

5.3.3 Các lựa chọn cạnh tranh về chi phí

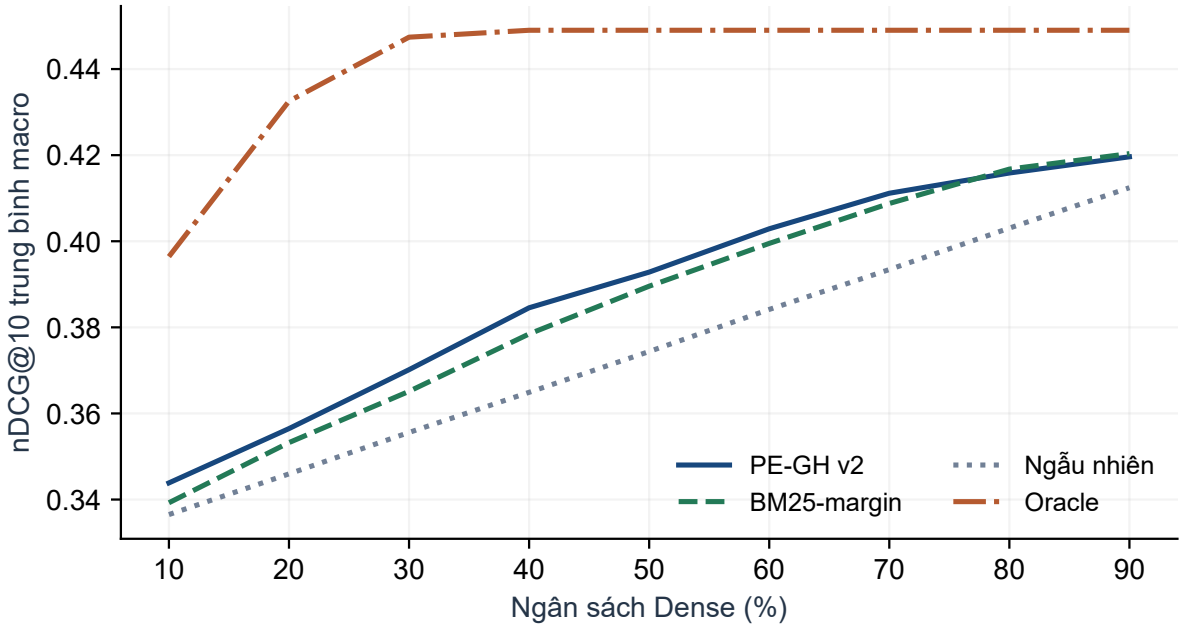
R^* đạt khoảng 14,70 ms và chất lượng 0,3811, trong khi PE-GH 50% đạt 14,76 ms và 0,3745 trên hai miền online. Hai điểm trung bình đặt cạnh nhau cho thấy chấm lại ứng viên BM25 là một đối chứng đáng chú ý tại vùng chi phí này. Chưa có kiểm định riêng trong bảng để kết luận R^* luôn tốt hơn, nhưng quan sát đủ để bác bỏ cách trình bày PE-GH như lựa chọn duy nhất đáng cân nhắc cho mọi mục tiêu thời gian.

R^* và PE-GH tiết kiệm ở những vị trí khác nhau. R^* mã hóa mọi truy vấn nhưng bỏ việc tìm kiếm vector trên toàn kho, còn PE-GH bỏ cả mã hóa và tìm vector cho một phần truy vấn. Do đó, phương án phù hợp phụ thuộc tương quan giữa chi phí mã hóa truy vấn, chi phí tìm vector và khả năng BM25 chứa tài liệu cần thiết trong tập ứng viên. Nếu chỉ dùng tỷ lệ sử dụng Dense làm đại diện toàn bộ chi phí, sự khác nhau này sẽ bị che khuất.

Nhánh P^* cũng cần được đối chiếu với BM25. Trong phiên đo chính, BM25 mất khoảng 2,03 ms và P^* khoảng 3,49 ms. Lợi ích chất lượng của P^* có tồn tại trên hai miền này, nhưng nhỏ hơn nhiều khoảng cách từ P^* đến H^*. Trên sáu miền xác nhận, phần xếp hạng bổ sung chỉ làm điểm trung bình tăng rất ít. Kết quả đặt ra câu hỏi liệu lợi ích đó có đủ để bù phần chi phí thêm vào nhánh được kỳ vọng là rẻ hay không.

5.4 Khả năng lựa chọn truy vấn

5.4.1 Lợi ích thay đổi theo ngân sách



Hình 5.3: Chất lượng theo ngân sách trên sáu miền xác nhận. Đường cong mô tả xu hướng và không thay thế kết quả kiểm định riêng của K1 và K2.

Hình 5.3 cho thấy lợi thế của PE-GH trước margin tập trung ở vùng ngân sách thấp và trung bình. Trong những điểm mô tả từ 10% đến 70%, PE-GH cao hơn margin khoảng 0,002 đến 0,006 nDCG@10. Từ 80% trở lên, điểm quan sát của margin nhỉnh hơn nhẹ. Đường cong vì thế không hỗ trợ một kết luận rằng bộ quyết định học có ưu thế ở mọi mức sử dụng Dense.

Khi ngân sách thấp, phương pháp phải chọn một tập nhỏ truy vấn đáng ưu tiên. Thứ tự điểm có thể tạo ra khác biệt rõ hơn trong vùng này. Khi ngân sách cao, phần lớn truy vấn đều đã được chuyển sang Hybrid, nên chỉ còn một nhóm nhỏ bị bỏ qua. Đây là một cách giải thích phù hợp với hình dạng đường cong, nhưng báo cáo không xem nó là bằng chứng trực tiếp rằng hai phương pháp đã chọn cùng một tập truy vấn. Kết luận về mức trùng tập lựa chọn cần bằng chứng về nhánh đã chọn cho từng truy vấn.

Điểm 50% của đường cong cho PE-GH khoảng 0,3928, khác số 0,3933 trong K1. Tương tự, mốc vận hành 80% là 0,4159, còn so khớp 80% trong đối chiếu bộ quyết định là 0,4156. Các chênh lệch nhỏ này đến từ những quy tắc phân bổ trong hồ sơ tương ứng. Báo cáo giữ đúng giá trị của từng giao thức, bởi chọn một con số thay cho con số khác sẽ làm mất quan hệ giữa bằng chứng và phép kiểm chứng.

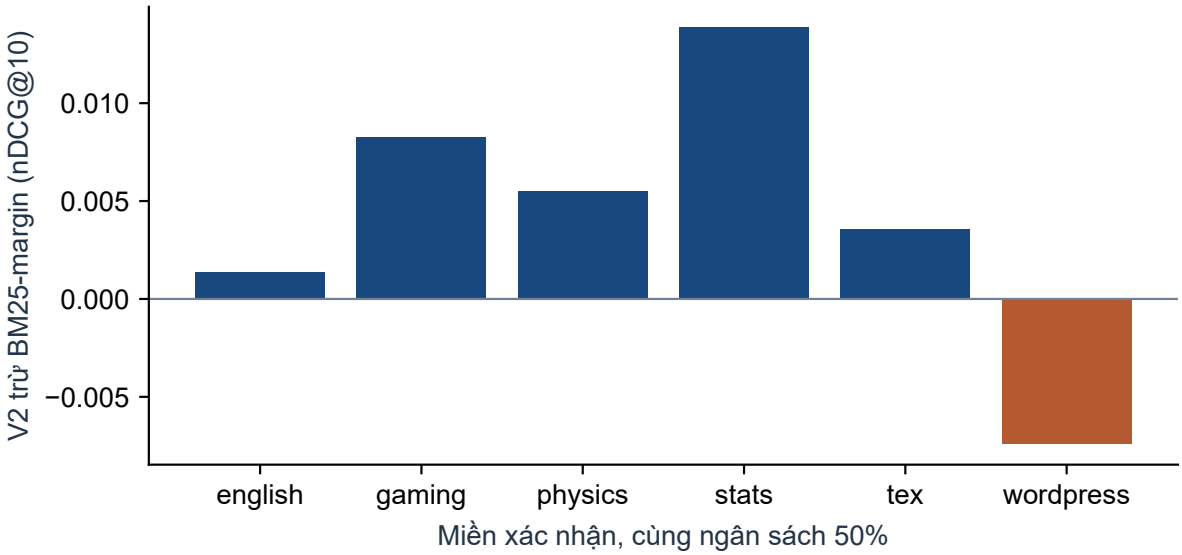
Oracle ở 50% đạt khoảng 0,4490, trong khi PE-GH ở vùng này khoảng 0,393. Khoảng cách lớn cho thấy còn nhiều khả năng lựa chọn tốt hơn nếu biết chất lượng thực tế của

hai nhánh. Oracle thậm chí có thể hơn luôn chạy Hybrid vì có thể tránh những truy vấn mà Hybrid làm giảm chất lượng. Tuy nhiên, nó sử dụng thông tin mà hệ thống phục vụ không có, nên không được diễn giải thành mức chất lượng có thể đạt ngay bằng một ngưỡng khác.

5.4.2 Dự báo BM25 và lợi ích hành động

PE-GH v2 có AUC dự đoán BM25 thất bại khoảng 0,764, so với khoảng 0,670 của margin trên sáu miền xác nhận. AUC của v2 cao hơn margin ở cả sáu miền. Đây là bằng chứng bộ quyết định sắp thứ tự rủi ro BM25 tốt hơn đối chứng theo mục tiêu dự báo đã chọn, nhưng mức cải thiện chất lượng truy xuất K1 vẫn chỉ khoảng 0,0042.

Sự khác biệt giữa hai mức hiệu quả phù hợp với giới hạn của nhãn học đã nêu ở Chương 3. Trong phân tích thăm dò, AUC của v2 đối với nhãn Hybrid có lợi hơn nhánh rẻ chỉ khoảng 0,570, thấp hơn AUC dự báo BM25 thất bại. Nhãn được dự đoán tốt hơn không hoàn toàn trùng với đại lượng quyết định chất lượng của nhánh được chọn. Do đó, báo cáo không dùng AUC 0,764 để thay cho bằng chứng rằng mọi truy vấn được ưu tiên đều hưởng lợi từ Dense.



Hình 5.4: Chênh lệch v2 trừ margin theo miền ở cùng ngân sách 50%. WordPress có chênh lệch âm dù AUC dự báo BM25 của v2 cao hơn margin.

Các so sánh thăm dò còn cho thấy một bộ quyết định dùng ít thông tin hơn vẫn có thể đạt chất lượng gần bản đầy đủ. Thay mục tiêu học sang nhận biết BM25 thất bại cũng đem lại kết quả đáng chú ý trong những phương án được thử. Những quan sát này gợi ý rằng lựa chọn điều cần dự báo có thể quan trọng hơn việc tăng độ phức tạp. Tuy nhiên, các thay đổi chưa được tách biệt hoàn toàn, nên báo cáo chưa quy phần cải thiện cho một nguyên nhân riêng.

Kết quả cần được dùng để giới hạn mô tả đóng góp. Bộ quyết định v2 là cấu hình đã được xác nhận trước margin trong đề tài, nhưng hiệu ứng nhỏ và phụ thuộc ngân sách. Giá trị phương pháp nằm ở việc chứng minh một cách lựa chọn hữu ích trong điều kiện cụ thể, cùng khả năng chỉ ra khi nào tín hiệu dự báo chưa chuyển thành lợi ích hành động.

5.5 Đối chiếu các bộ quyết định liên quan

5.5.1 Chất lượng trên sáu miền xác nhận

Bảng 5.5: So sánh thăm dò các bộ quyết định ở cùng số lượt Dense. Tất cả dùng cùng hai nhánh truy xuất. Điểm 80% ở đây thuộc phép so khớp ngân sách, khác điểm vận hành 80% của K2.

Bộ quyết định	30%	50%	80%
PE-GH v2	0,3698	0,3933	0,4156
LiteGator mặc định	0,3671	0,3904	0,4172
LiteGator chọn cấu hình	0,3678	0,3913	0,4169
BERT điều chỉnh	0,3697	0,3924	0,4224
BM25-margin	0,3648	0,3892	0,4172

Nguồn: Đối chiếu thăm dò của nhóm trên sáu miền xác nhận.

Ở 30% và 50%, các điểm trung bình của PE-GH, BERT và LiteGator khá gần nhau. Tại 50%, PE-GH đạt 0,3933, bản LiteGator mặc định đạt 0,3904 và BERT đạt 0,3924. Khoảng tin cậy hai phía của chênh lệch với hai bộ quyết định này chứa 0 trong phân tích thăm dò. Do đó, bằng chứng chưa đủ để khẳng định PE-GH có chất lượng cao hơn hai phiên bản điều chỉnh, đồng thời cũng chưa chứng minh chúng tương đương.

Tại 80%, BERT đạt 0,4224, cao hơn PE-GH 0,4156. Chênh lệch PE-GH trừ BERT khoảng $-0{,}0068$, với khoảng tin cậy hai phía từ $-0{,}0094$ đến $-0{,}0044$. Đây là kết quả bất lợi cần được giữ trong đánh giá phương pháp. Việc PE-GH rẻ hơn về quyết định không xóa bỏ khả năng một bộ quyết định đắt hơn có chất lượng tốt hơn tại một ngân sách cụ thể.

Bản LiteGator được lựa chọn trên các miền phát triển đạt 0,3913 ở 50%, so với 0,3904 của bản mặc định. Ở 80%, bản được lựa chọn đạt 0,4169, cao hơn điểm trung bình của PE-GH nhưng khoảng tin cậy chênh lệch còn chứa 0. Giữ cả hai bản giúp tránh so phương pháp của nhóm đã qua lựa chọn với một đối chứng chưa được xem xét phương án phù hợp. Tuy vậy, BERT chưa được khảo sát nhiều phương án ở cùng mức, nên phép đối chiếu vẫn có giới hạn về cân bằng chi phí phát triển.

5.5.2 Chi phí online trong phiên đối chiếu riêng

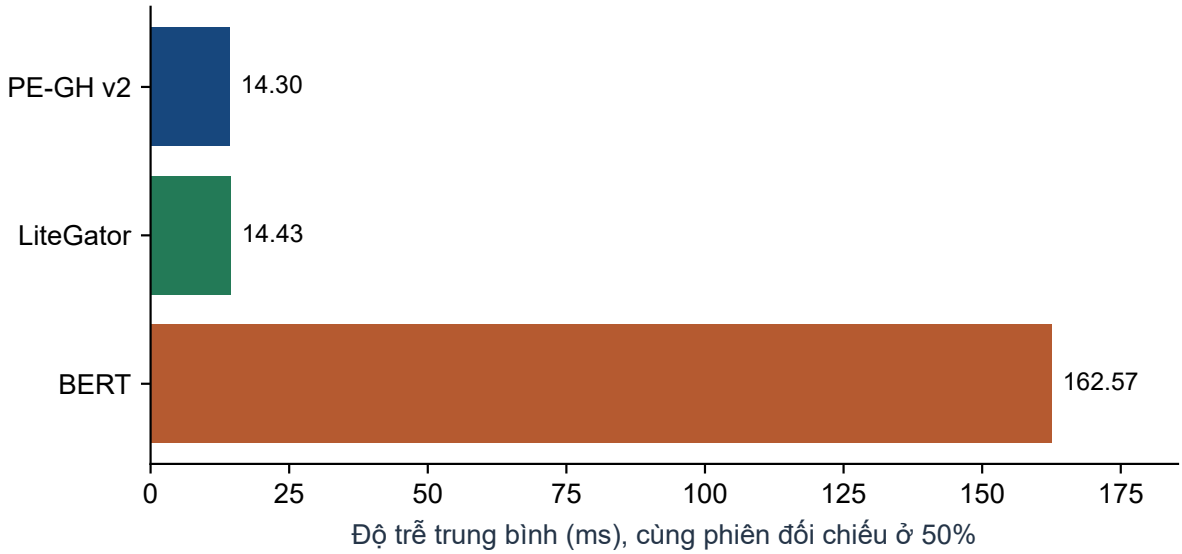
Trong phiên đối chiếu, PE-GH 50% đạt độ trễ trung bình 14,30 ms, LiteGator 14,43 ms và BERT 162,57 ms. Phần chi phí của BERT lớn hơn rõ rệt so với hai mô hình nhẹ, và

Bảng 5.6: Phiên đo đối chiếu bộ quyết định trên Programmers và Unix ở ngân sách 50%. LiteGator là bản được lựa chọn trên dữ liệu phát triển; các phương án được đo trong cùng điều kiện và cùng phiên.

Bộ quyết định (50%)	Mean (ms)	p95 (ms)	nDCG@10
PE-GH v2	14,30	26,98	0,3736
LiteGator chọn cấu hình	14,43	27,56	0,3674
BERT điều chỉnh	162,57	264,86	0,3692

Nguồn: Phiên online đối chiếu bộ quyết định của nhóm.

thậm chí lớn hơn mốc luôn chạy Hybrid khoảng 23,11 ms trong chính phiên này. Như vậy, một bộ quyết định có thể hữu ích về thứ tự lựa chọn nhưng không phù hợp với mục tiêu giảm chi phí CPU trong cấu hình phục vụ đang xét.



Hình 5.5: Độ trễ trung bình của ba bộ quyết định ở ngân sách 50% trong phiên đối chiếu riêng. Hình thể hiện chi phí quan sát, không suy rộng tỷ lệ tăng tốc sang phần cứng khác.

Chênh lệch chất lượng PE-GH trừ BERT ở 50% khoảng 0,0043, với CI hai phía từ $-0{,}0039$ đến 0,0125. Vì khoảng này chứa 0, so sánh chưa phát hiện khác biệt chất lượng theo cách đọc khoảng tin cậy đang dùng. Cùng lúc, chênh lệch độ trễ trung bình khoảng $-148{,}27$ ms có khoảng tin cậy từ $-150{,}65$ đến $-145{,}86$ ms. Hai bằng chứng hỗ trợ nhận định PE-GH rẻ hơn rõ trong phiên này mà chưa cho thấy khác biệt chất lượng rõ, nhưng chưa chứng minh hai bộ quyết định tương đương chất lượng.

Với LiteGator 50%, PE-GH có chênh lệch chất lượng khoảng 0,0061, CI hai phía từ $-0{,}0003$ đến 0,0127. Chênh lệch mean khoảng $-0{,}13$ ms có CI từ $-0{,}55$ đến 0,27 ms. Các khoảng hai phía đều chứa 0, nên chưa có bằng chứng rõ rằng PE-GH cải thiện cả chất lượng lẫn tốc độ trước đối chứng nhẹ này. Kết quả làm hẹp phạm vi kết luận phù hợp: đề tài chứng minh lợi ích trước margin theo K1, chưa chứng minh thắng LiteGator về mọi đại lượng.

Phiên đối chiếu sử dụng mô hình được lựa chọn mà không có miền đang đo; các phương án được đánh giá trong điều kiện chung. Kết quả có cơ sở để so sánh bên trong phiên này, nhưng khoảng tin cậy chưa lượng hóa biến động giữa các máy hoặc nhiều phiên vận hành độc lập. Do đó, mức chênh lệch thời gian với BERT chỉ được gắn với phép đo CPU đã thực hiện.

5.6 Các trường hợp chưa đáp ứng kỳ vọng

5.6.1 WordPress và giới hạn của kết quả trung bình

WordPress là trường hợp rõ nhất cho thấy lợi ích macro không bảo đảm lợi ích từng miền. Ở cùng ngân sách 50%, v2 đạt khoảng 0,3303 trong khi margin đạt 0,3377. AUC BM25 của v2 tại miền này vẫn khoảng 0,772, cao hơn margin khoảng 0,685. Hai quan sát cùng tồn tại cho thấy dự báo đúng hơn một biến liên quan chưa bảo đảm phân bổ ngân sách tốt hơn cho chất lượng cuối cùng.

Ở ngân sách vận hành 80%, WordPress đạt khoảng 0,3574 so với H^* 0,3686. Mức giảm điểm trung bình khoảng 0,0112 đặt ngoài biên 0,01 nếu xét riêng miền. Giao thức không đặt K2 riêng cho WordPress, nên đây là một giới hạn triển khai rút ra từ mô tả, không phải một phép kiểm định xác nhận mới. Trong sử dụng cho một cộng đồng cụ thể, cần xác định lại tiêu chí chất lượng của cộng đồng đó thay vì dựa hoàn toàn vào kết luận macro.

5.6.2 TeX và sự khác nhau giữa mức chất lượng và mức mất mát

TeX có 2.906 truy vấn, là miền lớn nhất trong nhóm xác nhận. Điểm H^* khoảng 0,3185, thấp hơn các miền như English hoặc Gaming, nhưng PE-GH 80% đạt khoảng 0,3179 và chỉ mất khoảng 0,0006. Một miền có điểm tuyệt đối thấp vì thế chưa chắc là miền bị lựa chọn nhánh làm tổn hại nhiều nhất. Cần phân biệt hạn chế của cả hai retriever với phần chất lượng mất thêm do bộ quyết định.

Nếu chỉ trình bày điểm tuyệt đối hoặc chỉ trình bày độ giảm, người đọc có thể có hai ấn tượng không đầy đủ về TeX. Báo cáo giữ đồng thời cả hai để cho thấy mục tiêu lựa chọn là kiểm soát mất mát trước một mốc Hybrid xác định, còn việc nâng chất lượng của chính mốc đó là một vấn đề khác. Quan sát này cũng giải thích vì sao chỉ tối ưu bộ quyết định chưa đủ giải quyết toàn bộ những miền khó.

5.6.3 Ảnh hưởng của chất lượng các nhánh truy xuất

Phương án Arctic được chọn đạt H^* khoảng 0,4133 trên hai miền phát triển, trong khi phương án Arctic ban đầu đạt khoảng 0,3469 và MiniLM đạt khoảng 0,3146. Thời gian mã hóa trung vị của phương án được chọn khoảng 8,72 ms, gần MiniLM 8,78 ms. Kết

Bảng 5.7: Các phương án mô hình ngữ nghĩa được xem xét trên Programmers và Unix. Thời gian mã hóa thuộc phép đánh giá mô hình, không phải toàn bộ thời gian trả kết quả cho một truy vấn.

Encoder	H^* macro	Mã hóa trung vị (ms)
MiniLM	0,3146	8,78
BGE-small	0,4018	15,94
Arctic ban đầu	0,3469	8,31
Arctic được chọn	0,4133	8,72

Nguồn: Thực nghiệm chọn encoder của nhóm trên Programmers và Unix.

quả cho thấy chất lượng của mô hình ngữ nghĩa và cách áp dụng cho nhiệm vụ có ảnh hưởng riêng đến hệ thống, bên cạnh quyết định truy vấn nào cần sử dụng mô hình đó.

Quan sát này không chứng minh một mô hình ngữ nghĩa luôn tốt hơn trên mọi bài toán. Nó cho thấy việc đánh giá bộ quyết định cần dựa trên những nhánh truy xuất có chất lượng đủ tốt. Nếu bỏ qua khác biệt giữa các nhánh, phần tiến bộ toàn hệ thống có thể bị quy sai cho khả năng lựa chọn truy vấn. Tương tự, lợi ích nhỏ của phần xếp hạng bổ sung trên các miền xác nhận cho thấy cần xem lại giá trị của nhánh chi phí thấp trong phạm vi sử dụng mới.

5.6.4 Giới hạn của phân tích trường hợp

Các trường hợp trên được đối chiếu ở mức miền và điểm vận hành từ kết quả tổng hợp. Bản thảo hiện chưa có phân tích đầy đủ từng truy vấn v2, bao gồm nội dung câu hỏi, nhánh được chọn và mức liên quan của danh sách trả về. Vì vậy, chưa đủ bằng chứng để giải thích thất bại của WordPress bằng một loại từ ngữ hoặc quy kết quả của TeX cho một kiểu câu hỏi cụ thể. Những ví dụ minh họa trong phần giới thiệu cũng không được dùng thay cho bằng chứng thực nghiệm này.

5.7 Giới hạn và ý nghĩa của kết quả

5.7.1 Mức độ giải quyết các mục tiêu

Về khả năng lựa chọn, K1 và K4 trả lời tích cực trong phạm vi xác nhận: bộ quyết định học hơn margin và ngẫu nhiên khi cùng ngân sách 50%. Hiệu ứng trước margin nhỏ, nên đóng góp phù hợp là cải thiện có kiểm chứng trong một vùng điều kiện, không phải thay thế mọi quy tắc rẻ. Đường cong và kết quả WordPress làm rõ ranh giới của nhận định này.

Về duy trì chất lượng, K2 cho phép giảm khoảng 20% lượt Dense với suy giảm macro nằm trong biên 0,01. Điều được giải quyết là một mục tiêu không kém hữu hạn ở mức gộp. Đề tài chưa bảo đảm không mất chất lượng, chưa bảo đảm từng miền thỏa cùng

biên và chưa bảo đảm tỷ lệ Dense của luồng truy vấn tương lai luôn đúng ngân sách đã đặt.

Về chi phí, phép đo chính hỗ trợ giảm độ trễ trung bình và CPU, nhưng không cho thấy lợi ích đồng đều cho p95 hoặc RSS. Điều này nhất quán với việc mô hình Dense vẫn cần sẵn sàng hoạt động và các yêu cầu sử dụng Dense vẫn đi qua nhánh đắt. Báo cáo vì vậy giới hạn đóng góp vận hành ở những đại lượng đã đo, không chuyển độ trễ trung bình thành lời hứa về mọi trải nghiệm thời gian phản hồi.

5.7.2 Độ khái quát và những yếu tố gây nhiễu

Mười hai miền tạo ra sự đa dạng chủ đề nhưng vẫn thuộc một bộ dữ liệu và một kiểu nhiệm vụ. Sáu miền xác nhận cung cấp kiểm chứng tốt hơn việc chỉ xem lại miền phát triển, song chưa thay thế đánh giá trên nguồn dữ liệu khác. Mọi nghiên cứu tiếp theo được lựa chọn từ các kết quả hiện tại cần một tập xác nhận chưa sử dụng nếu muốn có mức bằng chứng tương tự.

Đo khi phục vụ truy vấn chỉ thực hiện trên hai miền và một máy sử dụng CPU. Các con số phụ thuộc mô hình ngữ nghĩa, quy mô kho câu hỏi và điều kiện sử dụng tài nguyên. Thực nghiệm chưa đánh giá tình huống nhiều người dùng gửi yêu cầu đồng thời. Vì vậy, kết quả cho thấy lợi ích trong môi trường đã đo, nhưng cần đánh giá khác trước khi kết luận về khả năng phục vụ của một hệ thống thực tế.

Hệ thống có sử dụng truy vấn không nhãn của miền đích để thích nghi với đặc điểm dữ liệu trước khi đánh giá. Điều kiện này khả thi khi có một tập truy vấn đại diện, nhưng khác trường hợp triển khai ngay trên miền hoàn toàn chưa có dữ liệu. Nếu cách đặt câu hỏi hoặc nhu cầu tìm kiếm thay đổi, tỷ lệ chuyển nhánh và độ tin cậy của quyết định cũng có thể thay đổi. Bằng chứng hiện tại chưa lượng hóa được ảnh hưởng đó.

So sánh các bộ quyết định liên quan vẫn chịu ảnh hưởng của cách điều chỉnh mục tiêu và phạm vi khảo sát phương án. BERT chưa được lựa chọn ở cùng mức với hai bộ quyết định nhẹ. Các khoảng tin cậy thăm dò cũng chưa hiệu chỉnh cho toàn bộ phép so sánh bổ sung. Những điều kiện này không làm số đo mất giá trị, nhưng giới hạn cách khẳng định ưu thế trước công trình gốc.

Chương 6
Kết luận và hướng phát triển

6.1 Trả lời các câu hỏi nghiên cứu

Báo cáo nghiên cứu việc lựa chọn truy vấn cần truy xuất ngữ nghĩa trước bước mã hóa. Xuất phát từ sự khác nhau giữa nhu cầu của từng truy vấn, PE-GH sử dụng thông tin BM25 để phân bổ phần chi phí Dense thay vì luôn thực hiện Hybrid. Hệ thống cuối được xây dựng theo ràng buộc bộ quyết định nhẹ và được đánh giá bằng chất lượng, tỷ lệ Dense cùng chi phí đầu cuối.

Câu hỏi về khả năng lựa chọn được trả lời bằng K1 và K4. Trên sáu miền xác nhận, PE-GH v2 hơn BM25-margin khoảng 0,0042 và hơn ngẫu nhiên khoảng 0,0190 nDCG@10 ở cùng ngân sách 50%, với các giả thuyết đạt tiêu chí sau hiệu chỉnh Holm. Bằng chứng hỗ trợ giá trị riêng của bộ quyết định học trong phạm vi đó. Tuy nhiên, lợi ích trước margin nhỏ, không xuất hiện ở mọi miền và không duy trì ưu thế trên toàn bộ ngân sách.

Câu hỏi về giảm Dense trong biên chất lượng được trả lời tích cực ở điểm vận hành 80%. PE-GH đạt 0,4159 so với 0,4223 của luôn chạy Hybrid trên sáu miền xác nhận. Mức giảm khoảng 0,0064 nằm trong biên không kém 0,01 theo kiểm định đã đăng ký. Kết luận này chấp nhận mất mát có giới hạn ở mức macro, không khẳng định giữ nguyên chất lượng hoặc bảo đảm cùng biên cho mọi miền.

Câu hỏi về lợi ích online được hỗ trợ bởi phiên đo trên Programmers và Unix. Tại ngân sách 50%, độ trễ trung bình giảm từ 24,31 ms của Hybrid xuống 14,76 ms, tương ứng khoảng 39,3% trong cùng phiên. Ở 80%, mức giảm độ trễ trung bình khoảng 13,7%. CPU cũng giảm, trong khi p95 và bộ nhớ không cải thiện đồng đều. Vì vậy, lợi ích vận hành được xác định theo từng điểm chất lượng và đại lượng cụ thể.

Cuối cùng, v2 tốt hơn v1 trong so sánh toàn hệ thống, nhưng encoder và nhiều thành phần cùng thay đổi. Đối chiếu thăm dò với BERT và LiteGator làm rõ thêm giới hạn: PE-GH có chi phí thấp hơn BERT trong phép đo CPU, song BERT có chất lượng cao hơn ở 80% trên sáu miền xác nhận; trước LiteGator, các CI chưa cho bằng chứng rõ về ưu thế chất lượng hoặc tốc độ của PE-GH. Những kết quả này ngăn việc mở rộng kết luận thành ưu thế trước mọi phương pháp liên quan.

6.2 Đóng góp và mức độ giải quyết

Đóng góp phương pháp của đề tài là cách lựa chọn truy vấn trước bước mã hóa, dựa trên thông tin có sẵn từ BM25. Bộ quyết định nhận biết nguy cơ BM25 thất bại và sử dụng ngân sách để điều chỉnh mức dùng Dense, với chi phí lựa chọn đủ thấp để có thể tạo ra

lợi ích đầu cuối. Ý tưởng lựa chọn chiến lược truy xuất đã có trong tài liệu; đóng góp được giới hạn ở cách tiếp cận cụ thể và bằng chứng của đề tài.

Đóng góp thực nghiệm là kết nối các phép so cùng ngân sách, kiểm định chất lượng và đo online có đối chiếu kết quả. Quy trình giữ riêng phát triển, xác nhận và thăm dò, đồng thời công bố hiệu ứng nhỏ, trường hợp bất lợi và những đại lượng không cải thiện. Điều này giúp người đọc đánh giá mức độ giải quyết bài toán mà không phải suy luận từ một chỉ số đơn lẻ.

Phạm vi đã giải quyết là CQADupStack với hệ thống và điều kiện CPU được chốt. Báo cáo chưa chứng minh hiệu quả ngoài bộ dữ liệu, trên tải đồng thời hoặc trên phần cứng khác. Phân tích từng truy vấn v2 và độ bền trước thay đổi phân phối cũng còn cần được bổ sung. Những giới hạn này là cơ sở để xác định bước nghiên cứu tiếp theo.

6.3 Hướng phát triển

Hướng gần nhất là đánh giá phương án trả trực tiếp kết quả BM25 ở nhánh chi phí thấp, bởi phần xếp hạng bổ sung của P^* đem lại lợi ích nhỏ trên sáu miền xác nhận. Cần kiểm tra cả chất lượng và độ trễ trong cùng điều kiện trước khi kết luận đơn giản hóa có lợi. Một hướng khác là xem xét các phương pháp tìm kiếm ngữ nghĩa có chi phí thấp hơn [30], nhằm cải thiện cả những truy vấn vẫn phải sử dụng Dense. Hướng này xuất phát từ việc thời gian của nhóm yêu cầu chậm nhất chưa giảm nhất quán khi chỉ lựa chọn bớt truy vấn.

Để mở rộng mức bằng chứng, hệ thống cần được kiểm tra trên bộ dữ liệu chưa tham gia lựa chọn và trên môi trường phần cứng khác. Phân tích nội dung từng truy vấn, nhánh được chọn và chất lượng kết quả sẽ hỗ trợ tìm hiểu vì sao nhận biết BM25 thất bại chưa luôn dẫn đến lựa chọn hữu ích. Mọi thay đổi được chọn từ kết quả hiện tại cần có giao thức và tập xác nhận mới. Các hướng này tiếp tục câu hỏi của đề tài bằng những phép kiểm chứng cụ thể, thay vì xem những giới hạn đang có là kết quả đã được giải quyết.

Tài liệu tham khảo

[1] D. Hoogeveen, K. M. Verspoor, and T. Baldwin, "CQADupStack: A benchmark data set for community question-answering research," in *Proc. ADCS*, 2015, pp. 1–8, doi: 10.1145/2838931.2838934.

[2] N. Thakur, N. Reimers, A. Rücklé, A. Srivastava, and I. Gurevych, "BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models," in *Proc. NeurIPS Datasets Benchmarks*, vol. 1, 2021. [Online]. Available: https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/65b9eea6e1cc6bb9f0cd2a47751a186f-Abstract-round2.html

[3] D. Carmel, E. Yom-Tov, A. Darlow, and D. Pelleg, "What makes a query difficult?" in *Proc. ACM SIGIR*, 2006, pp. 390–397, doi: 10.1145/1148170.1148238.

[4] N. Arabzadeh, X. Yan, and C. L. A. Clarke, "Predicting efficiency/effectiveness trade-offs for dense vs. sparse retrieval strategy selection," in *Proc. ACM CIKM*, 2021, pp. 2862–2866, doi: 10.1145/3459637.3482159.

[5] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Found. Trends Inf. Retr.*, vol. 3, no. 4, pp. 333–389, 2009, doi: 10.1561/1500000019.

[6] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, 2019, pp. 3980–3990, doi: 10.18653/v1/d19-1410.

[7] V. Karpukhin, B. Oguz, S. Min, P. Lewis, L. Wu, S. Edunov, D. Chen, and W.-t. Yih, "Dense passage retrieval for open-domain question answering," in *Proc. EMNLP*, 2020, pp. 6769–6781, doi: 10.18653/v1/2020.emnlp-main.550.

[8] J. Johnson, M. Douze, and H. Jégou, "Billion-scale similarity search with GPUs," *IEEE Trans. Big Data*, vol. 7, no. 3, pp. 535–547, 2021, doi: 10.1109/tbdata.2019.2921572.

[9] C. Hauff, D. Hiemstra, and F. de Jong, "A survey of pre-retrieval query performance predictors," in *Proc. ACM CIKM*, 2008, pp. 1419–1420, doi: 10.1145/1458082.1458311.

[10] S. Cronen-Townsend, Y. Zhou, and W. B. Croft, "Predicting query performance," in *Proc. ACM SIGIR*, 2002, pp. 299–306, doi: 10.1145/564376.564429.

[11] G. Faggioli, T. Formal, S. Marchesin, S. Clinchant, N. Ferro, and B. Piwowarski, "Query performance prediction for neural IR: Are we there yet?" in *Proc. ECIR*, 2023, pp. 232–248, doi: 10.1007/978-3-031-28244-7_15.

[12] Y. Zhou and W. B. Croft, "Query performance prediction in web search environments," in *Proc. ACM SIGIR*, 2007, pp. 543–550, doi: 10.1145/1277741.1277835.

[13] A. Shtok, O. Kurland, D. Carmel, F. Raiber, and G. Markovits, "Predicting query performance by query-drift estimation," *ACM Trans. Inf. Syst.*, vol. 30, no. 2, pp. 1–35, 2012, doi: 10.1145/2180868.2180873.

[14] A.-R. M. Darmanto and R. L. Atimi, "LiteGator: A lightweight and budget-aware retriever routing framework for low-resource question answering," in *Proc. iCAST-ES*, 2025, pp. 687–695, doi: 10.2991/978-94-6463-926-1_77.

[15] L. Xiong, C. Xiong, Y. Li, K.-F. Tang, J. Liu, P. Bennett, J. Ahmed, and A. Overwijk, "Approximate nearest neighbor negative contrastive learning for dense text retrieval," in *Proc. ICLR*, 2021. [Online]. Available: https://openreview.net/forum?id=zeFrfgyZln

[16] G. Izacard, M. Caron, L. Hosseini, S. Riedel, P. Bojanowski, A. Joulin, and E. Grave, "Unsupervised dense information retrieval with contrastive learning," *Trans. Mach. Learn. Res.*, 2022. [Online]. Available: https://openreview.net/forum?id=jKN1pXi7b0

[17] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in *Proc. ACM SIGIR*, 2009, pp. 758–759, doi: 10.1145/1571941.1572114.

[18] S. Bruch, S. Gai, and A. Ingber, “An analysis of fusion functions for hybrid retrieval,” *ACM Trans. Inf. Syst.*, vol. 42, no. 1, pp. 1–35, 2024, doi: 10.1145/3596512.

[19] O. Khattab and M. Zaharia, “ColBERT: Efficient and effective passage search via contextualized late interaction over BERT,” in *Proc. ACM SIGIR*, 2020, pp. 39–48, doi: 10.1145/3397271.3401075.

[20] K. Santhanam, O. Khattab, J. Saad-Falcon, C. Potts, and M. Zaharia, “ColBERTv2: Effective and efficient retrieval via lightweight late interaction,” in *Proc. NAACL-HLT*, 2022, pp. 3715–3734, doi: 10.18653/v1/2022.naacl-main.272.

[21] T. Formal, B. Piwowarski, and S. Clinchant, “SPLADE: Sparse lexical and expansion model for first stage ranking,” in *Proc. ACM SIGIR*, 2021, pp. 2288–2292, doi: 10.1145/3404835.3463098.

[22] E. Kamalloo, N. Thakur, C. Lassance, X. Ma, J.-H. Yang, and J. Lin, “Resources for brewing BEIR: Reproducible reference models and statistical analyses,” in *Proc. ACM SIGIR*, 2024, pp. 1431–1440, doi: 10.1145/3626772.3657862.

[23] C. Kamphuis, A. P. de Vries, L. Boytsov, and J. Lin, “Which BM25 do you mean? a large-scale reproducibility study of scoring variants,” in *Proc. ECIR*, 2020, pp. 28–34, doi: 10.1007/978-3-030-45442-5_4.

[24] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, “MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020, pp. 5776–5788. [Online]. Available: https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

[25] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proc. NAACL-HLT*, 2019, pp. 4171–4186, doi: 10.18653/v1/n19-1423.

[26] K. Järvelin and J. Kekäläinen, “Cumulated gain-based evaluation of IR techniques,” *ACM Trans. Inf. Syst.*, vol. 20, no. 4, pp. 422–446, 2002, doi: 10.1145/582415.582418.

[27] M. D. Smucker, J. Allan, and B. Carterette, “A comparison of statistical significance tests for information retrieval evaluation,” in *Proc. ACM CIKM*, 2007, pp. 623–632, doi: 10.1145/1321440.1321528.

[28] J. Urbano, H. Lima, and A. Hanjalic, “Statistical significance testing in information retrieval: An empirical analysis of type I, type II and type III errors,” in *Proc. ACM SIGIR*, 2019, pp. 505–514, doi: 10.1145/3331184.3331259.

[29] S. Holm, “A simple sequentially rejective multiple test procedure,” *Scand. J. Stat.*, vol. 6, no. 2, pp. 65–70, 1979. [Online]. Available: https://www.jstor.org/stable/4615733

[30] Y. A. Malkov and D. A. Yashunin, “Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 42, no. 4, pp. 824–836, 2020, doi: 10.1109/tpami.2018.2889473.